

## 摘 要

为了适应日益增长的宽带信号和非线性系统的工程应用，用于分析瞬态电磁散射问题的时域积分方程方法研究日趋活跃。本文以时域积分方程时间步进算法及其快速算法为研究课题，重点研究了时间步进算法的数值实现技术、后时稳定性问题以及两层平面波算法加速计算等，主要研究内容分为四部分。

.....

**关键词：**时域电磁散射，时域积分方程，时间步进算法，后时不稳定性，时域平面波算法



## ABSTRACT

With the widespread engineering applications ranging from broadband signals and non-linear systems, time-domain integral equations (TDIE) methods for analyzing transient electromagnetic scattering problems are becoming widely used nowadays. TDIE-based marching-on-in-time (MOT) scheme and its fast algorithm are researched in this dissertation, including the numerical techniques of MOT scheme, late-time stability of MOT scheme, and two-level PWTD-enhanced MOT scheme. The contents are divided into four parts shown as follows.

**Keywords:** time-domain electromagnetic scattering, time-domain integral equation (TDIE), marching-on in-time (MOT) scheme, late-time instability, plane wave time-domain (PWTD) algorithm



# 目 录

<b>第一章 绪 论</b>	1
1.1 研究工作的背景与意义	1
1.2 国内外研究现状	2
1.2.1 图网络模型算法研究	2
1.2.2 文本分类算法研究	3
1.3 主要研究内容	6
1.3.1 整体文本分类算法设计	6
1.3.2 方面级情感分析算法设计	6
1.4 论文组织结构	7
<b>第二章 相关理论及技术</b>	8
2.1 文本分类任务	8
2.1.1 整体文本分类和方面级情感分析	8
2.2 单词嵌入表示	10
2.3 图模型相关理论	12
2.3.1 图卷积神经网络	13
2.4 注意力机制	15
2.4.1 注意力机制计算	16
2.4.2 自注意力与多头注意力机制	17
2.5 其他相关技术模型	18
2.5.1 TF-IDF	18
2.5.2 CNN 文本分类	19
2.5.3 门控机制	19
2.5.4 BERT 模型	21
<b>第三章 基于图模型的整体文本分类算法</b>	22
3.1 引言	22
3.2 问题定义	23
3.3 算法模型设计	23
3.3.1 模型总览	23
3.3.2 文本数据建模为图结构	25
3.3.3 表示学习过程	26

3.3.4 向量融合及分类 .....	28
3.4 实验设置 .....	29
3.4.1 数据集描述及数据处理 .....	29
3.4.2 对比方法介绍 .....	31
3.4.3 模型训练及验证 .....	32
3.4.4 实验评价指标 .....	33
3.5 实验结果及分析 .....	34
3.5.1 模型分类性能分析 .....	34
3.5.2 训练集比例的影响 .....	37
3.5.3 文本向量可视化分析 .....	38
3.5.4 本章小结 .....	39
<b>第四章 基于图模型的方面级情感分析算法 .....</b>	<b>40</b>
4.1 引言 .....	40
4.2 问题定义 .....	41
4.3 算法模型设计 .....	42
4.3.1 模型总览 .....	42
4.3.2 文本图建模过程 .....	43
4.3.3 词向量与超节点向量表示学习 .....	44
4.3.4 向量融合及分类 .....	47
4.4 实验设置 .....	47
4.4.1 数据集描述及数据处理 .....	47
4.4.2 对比方法介绍 .....	49
4.4.3 模型参数设置及评价指标 .....	50
4.5 实验结果及分析 .....	51
4.5.1 模型分类性能分析 .....	51
4.5.2 GAGCN 中使用的 GCN 与普通 GCN 对比 .....	53
4.5.3 数据增扩效果验证 .....	54
<b>致 谢 .....</b>	<b>55</b>
<b>附录 A 中心极限定理的证明 .....</b>	<b>56</b>
A.1 高斯分布和伯努利实验 .....	56
<b>参考文献 .....</b>	<b>57</b>
<b>攻读硕士学位期间取得的成果 .....</b>	<b>62</b>
<b>外文资料原文 .....</b>	<b>63</b>

外文资料译文 .....	64
--------------	----





## 第一章 绪 论

### 1.1 研究工作的背景与意义

文本分类是自然语言处理较为关键的一项任务，比如邮件分类、观点挖掘、情感分析等<sup>[1,2]</sup>。主要是通过对已知的一些文本进行训练学习，建立一个模型，挖掘文本中的深层次含义以及潜在规律，从而实现对未知文本的预测。例如，对于情感分类模型来说，通过输入用户的一句话或者一段话，实现对这段文本的分析，预测用户的情感，是消极还是积极。随着互联网的飞速发展，网络中存在着大量的文本数据，尤其是类似于美团、豆瓣等数字平台上充满了用户行为留下来的大量文本，如富有感情色彩的评论，对电影的点评、对美食的评价。以及各大新闻论坛也包含了多种多样的新闻主题，例如政治类、财经类、娱乐类。从这些海量数据中挖掘出用户的情感，有助于精准地刻画用户，从而辅助平台进行针对性的提供服务。同时，用户对某一事项的不同方面进行评价，有利于对这些方面的不足之处进行改进以提升用户感知。过去文本分类涉及了许多人工操作，例如新闻主题分类，依赖于工作人员的主观判断，将对应的新闻主体分类至对应的主题类目下。随着文本的不断累积，加上每天大量的新增文本，为手工分类带来了巨大挑战，极大的增加了人力成本。自动化的文本分类出现，能够显著降低劳动成本，提升工作效率。方面级的情感分类是指针对一段文本中指向的一个具体方面进行评价。例如一句话“这家餐馆的菜品很好吃，但是服务不太好”。这句话中主要提到了两个方面，一个是“菜品”，一个是“服务”。并且针对这两个方面有着不同的评价，分别是“很好吃”和“不太好”。方面级情感分类模型实现的就是对于“菜品”这个方面进行打分评价。相比于一般的文本分类针对的是一段文本或一句话进行的分类，方面级情感分类更加细分，需要捕捉到关键词的情感，更加注重于对某个关键词所表达的含义。互联网的高速发展，各大平台将会产生大量的文本信息，自动化的分类文本，通过用户发布的文本内容，精准地刻画用户情感，从而支持业务决策，正是本论文研究的意义和价值所在。传统的机器学习方法需要大量的手工提取特征的方式，增加了研究者的负担。而一些采用深度学习的方式在文本处理领域略有不足，例如很多算法忽略了文本的整体信息以及文本在语料库中的统计信息。尤其是在对于方面级目标词与文本内容之间关系的捕捉，很多模型仍有改进空间，因此文本分类任务的效率和准确度还有待提高。本学位论文研究基于图模型的文本分类算法，通过图模型有利于挖掘单词之间的关系信息，通过传递单词之间的信息，不断更新优化单词的向量表示，不断深入挖掘单词之间

隐藏的语义信息，同时文本的具体含义与整个语料库的组成也有一定联系，通过图模型捕捉所有文本单词之间的关联有助于提升分类效果。方面级目标词与文本整体的单词之间也应该有较大关联，用户对方面目标所体现的情感应该仅有文本中的部分词有关，而大部分词应该是无关的，本论文希望通过图模型挖掘出这些内在关系，有助于进一步提升文本分类质量。

## 1.2 国内外研究现状

本论文旨在研究基于图模型的短文本分类算法研究，因此接下来主要介绍图网络模型算法和文本分类算法目前的研究现状。

### 1.2.1 图网络模型算法研究

在许多领域的的数据都很容易转化成图结构。比如蛋白质组学、图像分析、社交网络和自然语言处理等。例如社交网络，每个用户都可以视作一个节点，他们之间的关系就可以构成一条条边，很自然的构成了一个图结构。由于图结构中的节点以及边都可以带有自己的属性信息，同时每个节点以及自己的邻居节点又可以构成一个新的拓扑图结构，因此基于图结构进行分析可以获取得到更加丰富的信息。图是由节点和边组成的一种结构，节点可以是任意实体对象，比如一个用户，一个地点或是一个单词，而边可以表示为节点之间的特殊联系，比如用户之间的点赞，互相关注等。如图1-1所示是一个基本的图结构。节点之间以边连接，形




图 1-1 图结构

成一个互相联系的结构。

近些年来，图神经网络已经被广泛应用于学习图的结构化向量表示。已经吸引了越来越多的学者<sup>[3-6]</sup>。图神经网络主要是通过迭代的方式聚集信息，例如某个节点，通过从周围的邻居节点中汇聚信息，然后对信息进行处理，获得自身新的

信息表示。再通过多次迭代，不断地更新自身的信息，获得丰富的特征向量表示。

图神经网络也包含多种，不同的网络也常对应不同的应用场景。许多传统的算法往往将图结构的数据压缩为链式结构，或者转换为树状结构，然后再使用链式神经网络（如 RNN）或递归神经网络去处理。此时，图中的拓扑结构信息往往会有有一定的损失，模型的性能也会受到压。基于此，Li<sup>[7]</sup> 提出了 GGNN（Gated Graph Neural Networks）模型，该模型直接可以使用图结构信息，利用一个 GRU 模型实现信息的传递。不同节点之间应该具有不同的关系，节点之间的信息传递应该依赖于关系的强弱进行传导，即关系度较高的两个节点之间传递的信息应该占比更多，而关系度低的节点之间应该仅传递较少的信息。而传统的图神经网络往往忽略了这种节点之间信息传递的强弱，Petar Velickovic 等人<sup>[8]</sup> 提出了一个基于注意力机制的图神经网络 GAT（Graph Attention Networks）。该网络利用每个节点的嵌入表示，采用一个自主力机制学到节点之间的权重关系，再通过这种关系进行信息的传递。该网络相比于许多传统的图神经网络模型取得了非常好的效果，但其弊端就是增加了计算量，每次都需要计算相关的权重信息。

图神经网络中，用得较为广泛的就是 Kipf<sup>[9]</sup> 等人提出的图卷积神经网络 GCN（Graph Convolutional Networks）。GCN 是一个多层的神经网络，首先我们定义一个图  $G = (V, E)$ ，其中  $V$  代表图上的节点集合， $E$  表示为节点之间的边的集合。GCN 的包含输入一个节点的向量表示  $X$ ，以及表示图节点关系的邻接矩阵  $A$ 。在每一层神经网络中，每个节点只能从其直接邻居节点处汇聚信息，再加上自身的信息，形成新的表示。随着层次的加深，每个节点可以获取到更远的节点的信息，即获得了多跳的邻居信息。最终模型的输出就是每个节点的新的向量表示。GCN 的传播计算如下

$$H^{(l+1)} = \sigma(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}) \quad (1-1)$$

$$\hat{A} = A + I \quad (1-2)$$

其中  $I$  表示为单位矩阵，在原始的邻接矩阵上加上单位矩阵就是为了确保节点每次传递都能考虑到自身的信息。 $H^{(l)}$  表示为第  $l$  层的节点向量表示， $W^{(l)}$  表示为第  $l$  层的参数。 $\hat{D}$  为  $\hat{A}$  的度矩阵。

### 1.2.2 文本分类算法研究

先前大量的文本分类工作主要通过对文本单词特征的提取分析，采用特征工程、机器学习或是深度学习等方式实现文本的分类。本文主要探讨的是两类文本

分类，一种是定义为整体文本分类，即直接对于整个文本内容进行分类，例如一段文本。判断它是属于金融类或是娱乐类；一种是方面级情感分类，即是对文本中关注的某一个方面词进行分析，例如一段文本“这个店的服务很好，但是菜品不怎么样”，当方面词为‘服务’时，则分类结果是正面，当方面词为‘菜品’时，分类结果则是负面。两者采用的算法大致都是通用的，只是在部分细节上略有不同，方面级情感分类需要着重关注方面词的情感，在算法的研究上需要进一步精心设计

### 1.2.2.1 整体文本分类算法研究现状

#### (1) 基于特征工程的算法和单词嵌入

在机器学习中，识别关键的以及相关的特征对于分类任务来说至关重要，文本分类任务也是如此。特征工程就是针对对应的文本挖掘其特征表示，最大限度地从原始数据中提取特征以供算法和模型使用。单词嵌入就是将文本中的单词用能代表其内在含义的一个向量进行表征，生成计算机能够识别的方式，进而实现分类任务。

K. Sparck Jones<sup>[10]</sup> 提出了 IDF 的方法，这个方法可通过与词频连用以减少语料库中隐性常用词的影响，TF 便是词频。TF-IDF 联合使用，可以作为输入特征进行分类。T. Mikolov 等人<sup>[11,12]</sup> 提出了 Word2Vec 的方法，用以改进单词的向量表示。它采用了一个两层神经网络的基础架构，采用 CBOW 或是 Skip-gram 的模型训练文本单词，挖掘单词语义，将单词嵌入到一个高维的向量表示空间，最终获得每一个单词的一个向量表示。Glove<sup>[13]</sup> 方法也是一种学习单词表示的方法。他与 word2vec 类似，采用一个大型的语料库进行训练，将单词嵌入到高维空间，实现用一组向量表示单词。Glove 方法相比于 word2vec，考虑了这种全局词汇的共现信息，并且结合局部上下文窗口的方法的优点。Fastext<sup>[14]</sup> 可以用来学习词向量，也可以用来做一种快速简单有效的文本分类算法。但它也有一个缺点。因为它是对文本中的所有单词向量求和取平均，所以忽略了单词在文本中出现的顺序，可能导致错误的分类结果。

#### (2) 基于深度学习的算法

深度学习的概念源于人工神经网络的研究，例如含多个隐藏层的多层感知器就是一种深度学习结构。深度学习通过组合低层特征形成更加抽象的高层表示属性类别或特征，以发现数据的分布式特征表示。在自然语言处理方面，已提出了许多模型，尤其是文本分类这一任务上，更是不断有新的方法涌现。

RNN (Recurrent Neural Network) 是一类用于处理序列数据的神经网络，广泛应用于各类序列上，备受各类研究者所关注<sup>[15]</sup>。为解决 RNN 模型的梯度消失问

题, 提出了 LSTM<sup>[16]</sup> (Long Short-Term Memory) 长短期记忆网络。此外, 还有一个 RNN 变种, GRU<sup>[17]</sup> (Gate Recurrent Unit) 模型, 它简化了 LSTM 的门机制, 仅有一个重置门和更新门。Bi-LSTM<sup>[18]</sup> (Bidirectional Recurrent Neural Networks) 即双向 LSTM 网络, 考虑了文本的前后两个方向的信息。由 Kim 等人<sup>[19]</sup> 提出了 Text-CNN 模型, 将 CNN (Convolutional Neural Networks) 网络带入了文本处理领域。相继有人提出了 RCNN<sup>[20]</sup>, DRNN<sup>[21]</sup>, TBCNN<sup>[22]</sup> 等基于 CNN 理论的模型用于文本分类。Liang Yao<sup>[23]</sup> 等人提出了基于图卷积神经网络 (GCN) 的文本分类算法。该模型创新的将图卷积网络应用于文本分类领域, 将图神经网络引向了新的方向。近年来最引人瞩目的用于自然语言处理的模型当属于 transformer<sup>[24]</sup> 以及 bert<sup>[25]</sup> 模型, 将自然语言处理推向了一个新的高度。

### 1.2.2.2 方面级情感分类算法研究现状

#### (1) 基于传统机器学习的算法

Jiang 等人<sup>[26]</sup> 在面对应用在推特上的情感分类算法时, 首先合并一些独立的特征, 其次将一些相关的推文考虑进去作为新的特征, 通过这些方式, 改进分类算法。Wang 等人<sup>[27]</sup> 采用 n-gram 特征输入 SVM 中实现方面级的情感分类。Brychcín 等人<sup>[28]</sup> 结合利用了约束性方法获取的特征以及非约束性方法获取的特征, 将两种方式获得的特征结合通过最大熵分类器实现了方面级情感分类。

#### (2) 基于深度学习的算法

Tang 等人<sup>[29]</sup> 提出采用 LSTM 模型捕获目标词与句子之间的关系用以实现方面级情感分类。Xue 等人<sup>[30]</sup> 提出了一个采用了门机制的 CNN 模型, 实验结果相比传统的 LSTM 模型具有更高的准确率以及计算速度。Huang 等人<sup>[31]</sup> 基于 CNN 模型提出 PF-CNN 和 PG-CNN 两种变种用以实现方面级情感分类。Han 等人<sup>[32]</sup> 基于 LSTM 模型, 融合了注意力机制关注方面级目标词以及上下文内容。Li 等人<sup>[33]</sup> 利用 GRU 模型学习文本序列信息, 获取每个单词的隐藏层状态表示, 此外还利用一个协同注意力机制学习目标是及上下文的向量表示, 最后采用一个自注意力机制更新目标词与单词向量之间的权重, 获得最终的用以文本分类的向量表示。Huang 等人<sup>[34]</sup> 提出了一个 AOA (Attention-over-Attention) 模型, 该模型可以捕捉到方面目标词与文本内容之间的关系信息。Zhang<sup>[35]</sup> 提出采用图卷积神经网络 (GCN) 用以学习方面目标单词与文本内容单词之间的关系。首先它将文本通过解析树构建单词之间的关系, 利用这种关系构建了一个有向图。该模型采用一个 Bi-LSTM 模型用以学习文本单词之间的隐藏状态表示, 然后将每个单词的隐藏向量表示作为图卷积神经网络模型单词节点的初始化表示, 通过几次卷积操作, 生成新的向量表示。之后, 找到对应的方面目标词在 GCN 模型的输出向量, 再与 Bi-LSTM

模型的单词隐藏状态向量用注意力机制求得对应的关系权重。最后通过加权求和确定最终的情感向量表示。该方法实现了对句子语法的解析,以及语法对文本情感带来的影响,较为准确地地区分了单词之间联系,找到了情感相关词汇,实验结果上相比一些方法有了一定提升。HaoTang<sup>[36]</sup>结合 bert、transformer 以及 GCN 模型,进一步提升了模型的准确率。

### 1.3 主要研究内容

本文针对基于图模型的文本分类算法进行研究。根据文本内容,将单词作为节点,单词之间的邻接关系或是依赖关系作为边,构成图结构,再采用图模型算法进行文本分析,实现文本分类任务。基于此算法,再引入方面词处理,进一步实现方面级情感分类。因此,本文主要实现两个方面的研究,一是针对整体文本分类算法进行研究设计,采用图模型算法提升分类任务准确率。二是实现方面级情感分类。基于第一点的研究基础,将方面词考虑进模型,对算法进行改进,实现处理方面级情感分类任务,并以此提高分类准确率。

#### 1.3.1 整体文本分类算法设计

传统的文本分类算法忽略文本在语料库中整体的统计信息,以及单词之间的互相影响。因为单词之间互有关联,尤其是同一个句子中的单词含义应该与整个句子的语义有关,而通常的单词嵌入模型每个词向量仅有一种。本文第三章中将文本中的每个单词视作一个节点,采用滑动窗口构建拓扑图结构,采用图模型将单词之间的信息通过图网络互相传递,重新学得更符合整个句子语义的单词的表示。同时还结合每个单词在整个语料库的统计信息,进一步生成代表整个文本含义的特征向量表示。对于单词向量再采用常规的 CNN 模型、LSTM 模型进行分析,再与单词统计信息学的到特征向量相结合,最终实现文本分类任务

#### 1.3.2 方面级情感分析算法设计

方面级的目标词与文本内容单词之前应该存在许多联系,如果能够挖掘它们之间的内在关系,便能进一步学到情感信息。本文第四章利用第一点的算法进行扩充,将方面词引入通过图网络模型对单词之间的联系进行挖掘,重新学得文本中每个单词的向量以及方面目标词的向量。同时采用 GRU 门控机制,进行遗忘和选择记忆不同层节点信息。新学得的词向量更符合文本含义,并且词向量之间也构建了诸多内在联系。接着采用 attention 机制找出目标词和文本单词之间的关系,即找到最能表达目标词情感的其他单词,最后通过组合这些单词,获得特征向量,

实现方面级情感分类任务，提升分类效果。

## 1.4 论文组织结构

本文共分为五章，每章的主要内容如下：第一章绪论。本章主要从根据现实情况分析了文本分类任务的研究背景以及意义，同时简单介绍了图模型相关理论以及文本分类算法以及方面级情感分析算法的国内外研究现状。并对本文的主要研究内容进行了概括。

第二章相关理论及技术。本章首先介绍了文本的处理方式，以及常用的例如 word2vec、glove 等单词向量表示学习方法。随后总结了图模型相关理论，着重介绍了 GCN 网络原理及对关键问题进行了详细描述。接着介绍文本分类任务中常用的 GRU 门控机制、CNN 模型以及注意力机制原理。最后介绍了目前较为流行的 Bert 模型。

第三章基于图模型的整体文本分类算法。

第四章基于用户节点嵌入的多属性推断算法。

第五章总结与展望。总结全文的工作内容，展望未来的研究方向。

## 第二章 相关理论及技术

本章首先对文本分类任务进行简单介绍以及单词嵌入表示如 word2vec, glove 等学习方式。本章主要围绕了基于图模型文本分类模型的相关理论以及关键技术。包括图模型, 图卷积神经网络 (GCN), 注意力机制, 以及本文将会使用的技术和深度学习模型如 TF-IDF、GRU、CNN、Bert 等。

### 2.1 文本分类任务

在如今人类活动中产生了大量的文本数据, 如美团、大众点评上对美食的各类评论, 豆瓣上对书籍、电影的评价, 以及人类历史活动中各类简短信息, 例如微博、推特, 新闻摘要等。这类都是一些短文本, 对这类短文本进行分析一方面有助于实现快速归类, 对于不同类型的文本内容进行整理; 另一方面针对用户的平均分析用户行为, 改善服务。文本分类涉及多种情况, 本文主要探讨整体文本分类算法以及方面级情感分析算法。

#### 2.1.1 整体文本分类和方面级情感分析

##### (1) 整体文本分类

对于整体文本分类来说, 目的是对整段文本的描述进行判断, 以数据集 R8 为例, 该数据集为分类任务常用的文本数据集, 为路透社新闻文本, 共有八个分类。




图 2-1 R8 数据集



如图2-1所示, 截取了数据集中三个分类标签, 分别是 `earn`、`acq` 和 `crude`。每个类别下都有对应的文本, 代表了这个文本的分类属于这个标签。从图2-1可以看出, 整体文本分类任务是对整句话进行分类, 一般一个文本只属于一个类别。比如 “`Federated department stores march sales up`” 这句话, 从文意可以看出描述了联邦百货公司 3 月销售额上升, 正好符合 `earn` 标签的含义, 因此对于这段文本可以分类为 `earn`。总的来说, 本文定义的整体文本分类任务是针对于一个文本整体进行分类, 判断该段文本从属的标签类别, 一般情况下一个文本只有一个标签。

## (2) 方面级情感分析任务

方面级情感分析任务不同于整体文本分类任务, 它是对文本中存在的方面目标词进行分类, 而不是整段文本, 因此, 一段文本, 对于方面级情感分析任务来说, 存在多个方面目标词, 那么就可能存在多个类别标签。方面目标词即可以是一个单词也可以是一个词组。本文以 `semeval14` 数据集为例, 该数据集是 14 年推特的文本数据集, 常用来做情感分析。




图 2-2 semeval14 数据集

从图2-2可以看出, 该段文本共有三个由红色方框标注出来的方面目标词, 分别是 ‘`bar`’、‘`table`’、‘`dinner`’。方面级情感分析任务就是需要实现分别对这三个词的情感进行分析, 而不是对整个文本进行分类。因此相比于整体文本分类任务来说, 需要更精细的设计。比如 ‘`bar`’ 这个词, 从文本描述来看, 最能体现这个词情感信息的词应该是 ‘`enjoying`’, 而 ‘`enjoying`’ 代表了正面的情感, 因此对于 ‘`bar`’ 这个方面目标词把它归于 ‘正面情感’ 这个标签; 对于 ‘`table`’ 和 ‘`dinner`’, 这句话没有明显的情感, 仅仅作为描述语句或是补充, 因此没有特别的情感色彩, 把它们归属于 ‘无情感’ 的标签下。所以, 对于方面级情感分析任务来说, 需要根据方面目标词进行分析, 把握该词汇与其他具有情感色彩的词汇之间的关系, 分析具体的情感色彩指代。同一个句子中可能存在多个情感色彩词, 并且词的含义可能是相反的, 一个可能代表了积极正面的情感, 另一个可能是消极的负面情感。相比于整体文本分类任务来说, 更具有难度。

## 2.2 单词嵌入表示

文本数据不同于一般的图像、音频等数据。图像数据本身就具有意义，是天然带有的属性，即使没有经过训练的生物或许也能分辨不同的图片。而文本数据是人类的高层的抽象的思维信息表达的工具，具有高度抽象特征。在图像处理中，一张图片通常可以用一个矩阵表示，其中每个坐标的点即为像素点的值，矩阵中每个数值都具有一定意义，且矩阵属于稠密矩阵。而一段文本通常有多个单词构成，每个单词可以由一个向量表示，如图2-3所示。

I	0.9	0.23	0.11	0.35	0.09	0.01	...
Have	0.13	0.44	0.92	0.04	0.01	0.56	...
a	0.59	0.28	0.81	0.05	0.29	0.28	...
Dream	0.05	0.61	0.16	0.32	0.76	0.81	...
,	0.38	0.3	0.1	0.52	0.19	0.21	...
...							...

图 2-3 文本向量表示

如图2-3所示，一句话由多个向量组成，每个单词有一个向量表示，不同于图片矩阵，向量中的每个单一的值没有具体的含义，所有的值构成一个向量才具有表示为单词信息的含义。向量中的值一般取决于表示的方法。如采用 one-hot 的表示方式，向量中仅含有一个为 1 的值，其他值为 0。向量的维度由单词个数决定，如一个单词量为 2000 的词库，构成的单词向量即为  $1 \times 2000$  的向量。如单词 Dream 位于该词库中第二个位置，它的向量表示可能是  $(0, 1, 0, 0, \dots, 0)$ ，另一个单词 Have 可能位于第 1000 个位置，那么它的向量表示可能就是  $(0, 0, \dots, 1, \dots, 0, 0)$ 。每个单词都由一个唯一的向量表示。虽然这种方式非常简单，但同时带来许多问题。1. 向量维度随着单词数量而增加，当面对几万甚至几十万的词库时显得力不从心。2. 每个单词向量都仅仅由 0,1 构成，没有具体含义，难以把握单词之间的联系。

Hinton 提出的 Distributed Representation<sup>[37]</sup> 思想可以用以学习词向量解决这个问题。这类词向量的表示一般类似于  $(0.22, -0.17, \dots, 0.65, 0.01)$  这种。而现如今常用的学习词向量的方法有 word2vec, glove 等。

Word2vec 它采用了一个两层神经网络的基础架构，采用 CBOW 或是 Skip-

gram 的模型训练文本单词，挖掘单词语义，将单词嵌入到一个高维的向量表示空间，最终获得每一个单词的一个向量表示。




图 2-4 skip-gram 模型

Skip-gram 模型如图2-4所示，图左为模型架构，即通过中间单词预测该单词的上下文词。神经网络模型如图右所示。Skip-gram 训练模型仅包含一个没有激活函数的隐藏层，和使用 softmax 激活函数的输出层。对于一个包含  $V$  个单词的数据集，模型的输入是一个  $V$  维的 one-hot 向量，经过一个  $W_{V \times N}$  的矩阵转化为  $N$  维的向量  $h_t$ ，通常  $N$  远远小于  $V$ ，这样一来可以将单词维度下降到很小，而所谓的  $W_{V \times N}$  参数矩阵即是我们需要学习的词嵌入矩阵。之后在经过一个  $W'_{N \times V}$  的参数矩阵，将隐藏向量  $h_t$  转为一个  $V$  维的向量，经过 softmax 激活函数，向量中的每个值都在 0-1 之间，代表着预测的单词的概率。计算公式如下：

$$h_t = Wx_t \quad (2-1)$$

$$u_{t-1} = W'h_t \quad (2-2)$$

$$p(w_{t-1}|w_t) = y_{t-1} = \frac{\exp(u_{t-1})}{\sum_{j=1}^V \exp(u_j)} \quad (2-3)$$

其中  $W, W'$  分别为  $V \times N$  维， $N \times V$  维的参数矩阵， $p(w_{t-1}|w_t)$  表示单词  $w_t$  的上下文预测单词  $w_{t-1}$  的概率。

CBOW 模型如图2-5所示，图左为 COBW 模型架构，它与 skip-gram 相反，通过上下文信息预测中间词。首先是通过上下文多个单词计算隐层向量  $h_t$ ，计算公式




图 2-5 CBOW 模型

如2-5，主要采用上下文  $C$  个单词的加权和得出。接着与 skip-gram 类似通过输出层转化为  $V$  维向量，再通过 softmax 预测。

$$h_t = \frac{1}{C} W \sum_{i=1}^c x_i \quad (2-4)$$

Glove 方法也是一种学习单词表示的方法。他与 word2vec 类似，采用一个大型的语料库进行训练，将单词嵌入到高维空间，实现用一组向量表示单词。但是 word2vec 的 CBOW 和 skip-gram 方法是基于局部上下文窗口的，忽略了单词之间的共现信息。Glove 方法的提出，考虑了这种全局词汇的共现信息，并且结合局部上下文窗口的方法的优点，来学习词向量，相比 word2vec 效果得到了一定的提升。Glove 目标函数可以近似为：

$$F(w_i - w_j, w_k) = \frac{p_{ik}}{p_{jk}} \quad (2-5)$$

其中  $w_i, w_j, w_k$  分别代表单词  $i, j, k$  的表示向量， $p_{ik}$  代表单词  $k$  出现在单词  $i$  上下文的概率。Glove 的目标就是找到函数  $F$  的表示空间，从而得到所有单词的向量表示。

### 2.3 图模型相关理论

现实生活中存在着大量的图结构数据，比如分子结构，社交网络，地理位置。这些数据的关键点在于都有一个可抽象化的节点，比如社交网络中的用户，以及

连接这些节点的边即关系，比如社交网络中用户的关注、用户的点赞评论等交互。如何去利用这些图数据那就首先需要获取这些图数据中节点或是边的有效表示<sup>[38]</sup>。现如今已有大量关于图模型数据处理的研究<sup>[39-41]</sup>。

图神经网络（GNN）主要是利用神经网络去学习节点表示  $h_v$ ，或是整个图的向量表示  $h_G$ 。通常每个节点  $v$  会有一个初始的向量表示  $x_v$ ，经过图模型计算学习获得新的表示。而学习的过程主要是一种信息聚集的过程，即节点首先会从自己的邻居节点聚集信息，随着每一轮的聚集，当前节点将会获取到更远处节点的信息，即经过  $k$  轮迭代，当前节点或许可以得到  $k$ -跳的邻居节点信息，如下公式所示：

$$a_v^k f = (h_u^{k-1} : u \in \mathcal{N}(v)) \quad (2-6)$$

$$h_v^k = g([h_v^{k-1}, a_v^k]) \quad (2-7)$$

其中  $k$  表示第  $k$  次聚集， $a_v^k$  表示节点  $v$  从其邻居节点集合  $\mathcal{N}(v)$  聚集得到的信息。聚集过程可以采用简单的加权和，也可以根据算法自定义方式。主要功能就是将邻居节点的信息融合得到一个新的向量，即得到一个具有丰富信息的向量。随后节点  $v$  再将上一次迭代获取到的向量表示与当前聚集轮次获得到的邻居信息融合起来，组成新的该节点的向量表示。随着次数的增多，当前节点将会获取到多跳邻居节点的信息，使得当前节点的向量表示更加丰富，融入了多种信息，表达更加全面。

### 2.3.1 图卷积神经网络

Kipf 提出的图卷积神经网络<sup>??</sup>是一种直接在图上进行计算的半监督学习模型。首先定义一个图  $G = (V, E)$ ，其中  $V(|V| = n)$  表示图中的节点，共有  $n$  个， $E$  表示图中的边的集合。如图2-6所示每个节点都与其他某个或多个节点进行相连，构成了一个拓扑图。可以用邻接矩阵  $A$  表示节点之间的关系，如图2-7所示。其中两个节点之间如果有边，则矩阵对应位置的值为 1，反之则为 0。此外邻接矩阵对应的度矩阵  $D$  如图2-8所示。其中  $D_{ij} = \sum_j A_{ij}$ 。

假设每个节点  $v_i$  具有  $m$  维的特征向量  $x_i \in R^m$ ，因此  $n$  节点构成特征向量矩阵  $X \in R^{n \times m}$ 。节点信息在图中的传播主要沿着边进行，即通过边将每个节点的潜在信息进行传递。一个节点获取到来自其他节点的信息，将这些信息进行融合更新自身节点的信息，从而使得当前节点的信息更加丰富。每一次的信息传递都会增加额外的节点信息。刚开始，只会获取得到与当前节点直接相连的其他邻居节点




图 2-6 拓扑图

$$\begin{pmatrix} 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \end{pmatrix}$$

图 2-7 邻接矩阵 A

的信息，同理邻居节点也会获取得到其邻居节点的信息，随着传递次数的增加，当前节点获取到的信息不仅仅是直接相邻的节点信息，更能获取得到更远的不相邻节点的信息。Kipf 提出的图卷积计算方式可以由下公式得到：

$$H^{(l+1)} = \sigma(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}) \quad (2-8)$$

其中  $\hat{A} = A + I$ ,  $I$  表示为单位矩阵。在原始的邻接矩阵上加上单位矩阵就是为了确保节点每次传递都能考虑到自身的信息。 $H^{(l)}$  表示为第  $l$  层的节点向量表示， $W^{(l)}$  表示为第  $l$  层的参数。 $\hat{D}$  为  $\hat{A}$  的度矩阵。

$$\begin{pmatrix} 2 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 2 \end{pmatrix}$$

图 2-8 度矩阵 D

## 2.4 注意力机制




图 2-9 人类观察狗狗图

注意力机制就是模拟人类对视觉的处理，是源于对人类视觉的研究。人类通过眼睛观察周围场景，能够从有限的时间中快速挖掘场景中的信息，正是由于人类大脑提供的处理机制-注意力机制，让人能在复杂的场景中快速适应。人类对场景观察时，大部分情况下仅关注于重点区域，将大部分注意力资源都投入到这些区域中，而尽量忽略一些无关紧要的信息，实现资源的有限分配。这是人类与生俱来的赖以生存的机制，人类视觉的注意力机制大大提高了视觉信息处理的时效性以及准确性。如图2-9所示，人类对于图片的识别时，识别这张图像是猫还是狗，首先可能会把观察重点放在图片中存在的那个动物上，然后忽略图片中其他的场景，如图中红色线框所示，人类观察时，忽略了这个动物存在的场景，即忽略了周边的花草，因为这些信息对分析这个动物类别没有帮助。确定了大致区域后，视觉进一步将注意力放在耳朵，嘴巴，尾巴等位置上，从这些有限的区域就能大致分析出这个动物属于狗，而不是猫。因此，注意力机制对于实现有限的资源调度以及提升准确率（因为避免了类似花草场景的干扰）具有很大帮助。

注意力机制之前主要大量用于视觉处理，首次用于自然语言处理领域可以追溯到 Bahdanau<sup>[42]</sup> 等人在 2014 年提出的基于 RNN 的编码-解码翻译模型。该篇文章不同于以往的翻译模型——在编码阶段将所有单词编码为单一向量  $c$ ，这样的处理方式会使得模型在压缩信息的过程中不得不忽略一些信息，从而使得翻译模型在面对长句子时处理能力很差。Bahdanau 并没有固定编码向量  $c$ ，而是根据解码层每一步的隐藏状态与编码时每个单词的隐藏向量计算得到不断变化的编码向量  $c_i$ 。这种技巧就是一种注意力机制的处理方式，大大提高了模型的性能。

如图2-10所示就是采用了注意力机制（图上）和普通 RNN 模型（图下）的差异。以下介绍几种常用的注意力机制使用方式。



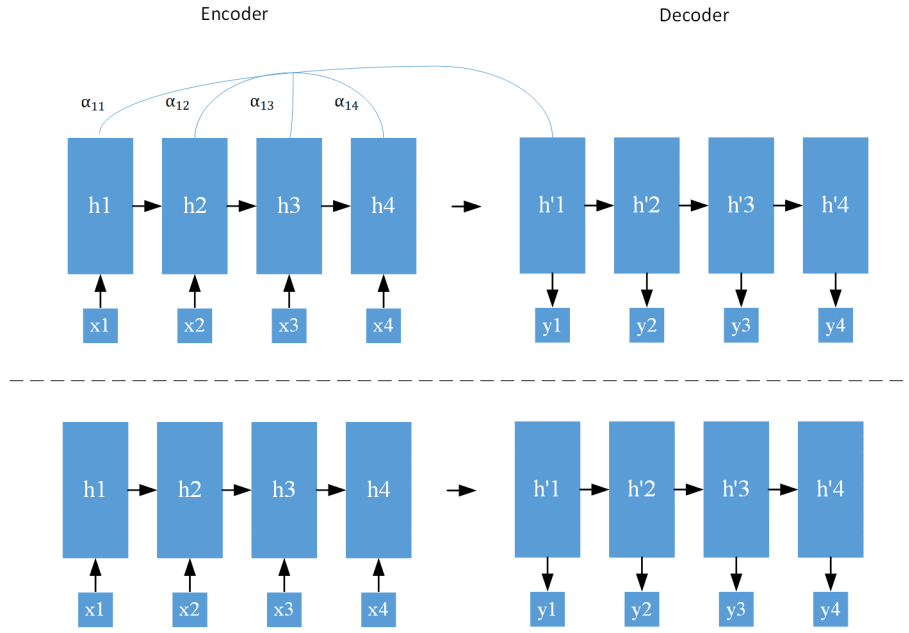


图 2-10 注意力机制 RNN（上）与普通 RNN（下）

### 2.4.1 注意力机制计算

在深度学习模型中，注意力机制计算可以简化为三类向量，一个是查询向量，即 query 向量，简称为  $q$ ；一个是关键词向量，即 key 向量，简称为  $k$ ；最后一类是值向量，即 value 向量，简称为  $v$ 。通常查询向量  $q$  是一种特定于任务的向量，例如在上文提到的翻译模型中， $q$  就是上一个隐藏状态向量。而  $k$  向量便是用来计算注意力分数的向量，如上文提到的翻译模型中的单词隐藏向量。 $v$  向量便是最终用于加权求和的向量。

注意力机制实现过程主要由以下公式计算得到 2-9、2-10、2-11。

$$a_i = \text{score}(q, k_i) \quad (2-9)$$

$$\alpha_i = \frac{\exp(a_i)}{\sum_j \exp(a_j)} \quad (2-10)$$

$$c = \sum_j v_j * \alpha_j \quad (2-11)$$

其中  $\text{score}(q, k_i)$  为根据关键向量  $k_i$  与查询向量  $q$  计算得到的注意力分数，有不同的计算方式。luong<sup>[43]</sup> 提出公式 2-12 和 2-13 所示的计算方式，其中  $W_a$  是一个



可训练的参数矩阵。Vaswani<sup>[24]</sup> 采用公式2-14的计算方式，其中  $n$  是向量的维度。

$$score(q, k_i) = q^T k_i \quad (2-12)$$

$$score(q, k_i) = q^T W_a k_i \quad (2-13)$$

$$score(q, k_i) = \frac{q^T k_i}{\sqrt{n}} \quad (2-14)$$

### 2.4.2 自注意力与多头注意力机制




图 2-11 自注意力机制

自注意力机制是一种关联单个序列的不同位置的注意力机制。通过计算每个位置与其他所有位置上的信息的注意力权重，从而获取得到对于当前位置最重要的一些信息，同时也能保留那些不重要的信息，更新当前位置的向量表示。如图2-11所示，单词‘touch’会计算所有其他单词的之间的注意力分数，分数大小由线段粗细为例，‘touch’可能更加关注于‘inner self’等单词，因此分配的权重也会更高，对于其他单词分配的权重会低一些。Lin<sup>[44]</sup> 采用注意力机制提出一个可解释性的文本嵌入模型，用于情感分析等任务上取得优异的结果。

多头注意力机制首次由 Vaswani<sup>[24]</sup> 等人提出。首先将 Query, Key, Value 进行线性变换，这里将计算多个线性变换，每个线性变换的参数均不一样。每一次的计算就是所谓的一个‘头’。然后采用放缩点积（scaled dot-Product attention）方




图 2-12 多头注意力机制

式计算，如公式2-14所示。最后将结果拼接通过再通过一个线性变换层输出得到。如图2-12所示。这样的好处就是可以允许模型在不同的表示子空间里学习到不同的相关信息。

## 2.5 其他相关技术模型

### 2.5.1 TF-IDF

TF-IDF 是一种统计方法，用以评估一个字词对于一个文件集或一个语料库中的其中一份文件的重要程度。字词的重要性随着它在文件中出现的次数成正比增加，但同时会随着它在语料库中出现的频率成反比下降。K. Sparck Jones<sup>[10]</sup> 提出了 IDF 的方法，这个方法可通过与词频连用以减少语料库中隐性常用词的影响。计算方法如公式2-15：

$$idf = \lg \frac{|D|}{|\{j : t_i \in d_j\}|} \quad (2-15)$$

其中  $D$  表示语料库中的文件总数，分母包含单词  $t_i$  的文件数目。TF 即是单词词频，表示如公式2-16所示：

$$tf = \frac{n_i}{\sum n_k} \quad (2-16)$$

其中  $n_i$  代表单词  $i$  出现的次数，分母为所有单词出现的总次数。TF-IDF 联合使用，可以表示为：如果某个词或短语在一篇文章中出现的频率 TF 高，并且在其他文章中很少出现，则认为此词或者短语具有很好的类别区分能力。因此可以根据这个方法来做分类。

## 2.5.2 CNN 文本分类

CNN (Convolutional Neural Networks) 模型是一类包含卷积计算且具有深度结构的前馈神经网络 (Feedforward Neural Networks)，是深度学习 (deep learning) 的代表算法之一。卷积神经网络 (CNN) 具有表征学习能力，最主要的特征就是具有平移不变性。CNN 最早可以追溯到日本科学家福岛邦彦<sup>[45]</sup>提出的一个包含卷积层、池化层的神经网络结构。虽然中间消沉了一段时间，仅仅有一些少量性的研究工作，但 Hinton 等人提出的 Alexnet<sup>[46]</sup>，颠覆了图像识别领域，从而再次吸引了大量人员对于 CNN 的研究。CNN 主要应用于视频、图像等领域，由 Kim 等人<sup>[19]</sup>提出了 Text-CNN 模型，将 CNN 网络带入了文本处理领域。




图 2-13 CNN 模型

如图2-13所示，一段文本可以用一个  $N \times D$  的矩阵表示，其中  $N$  代表文本中单词的数目， $D$  代表单词向量的维度。经过一个  $k \times D$  大小的卷积核操作，其中  $k$  表示为每次卷积操作的单词数，再经过一个池化层，得到一维向量表示。将多个卷积核操作获得的向量进行拼接，获得这段文本的向量表示。最后将这个向量表示输入一个分类器实现文本分类等任务。该 CNN 模型相比 RNN 模型，在一些比较的数据集来看，准确率相差不大，但是对于一些情感分类的文本来说有一定的优势。CNN 最具优势的一点就是它能够并行计算，因而相比传统的 RNN 模型，计算速度有了较大提升，极大地缩短了训练时常，在一些比较注重实效的场景下，可以选择 CNN 模型。

## 2.5.3 门控机制

LSTM、GRU 网络中采用了门控机制，实现了对短期记忆与长期记忆的结合，提升了模型性能，并且一定程度上解决了 RNN 模型的梯度消失问题。如图2-14所示，LSTM 模型采用了门结构，门就是一个选择信息通过或抛弃的机制。计算过程




图 2-14 LSTM 模型

如下：

$$f_t = \sigma(W_f \bullet [h_{t-1}, x_t] + b_f) \quad (2-17)$$

$$i_t = \sigma(W_i \bullet [h_{t-1}, x_t] + b_i) \quad (2-18)$$

$$\tilde{C}_t = \tanh(W_c \bullet [h_{t-1}, x_t] + b_c) \quad (2-19)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (2-20)$$

$$o_t = \sigma(W_o \bullet [h_{t-1}, x_t] + b_o) \quad (2-21)$$

$$h_t = o_t * \tanh(C_t) \quad (2-22)$$

LSTM 中包含三个门结构，遗忘门、输入门以及输出门。遗忘门的计算首先通过之前的信息  $h_{t-1}$  以及当前输入信息  $x_t$  计算得到  $f_t$ ，一个在 0-1 之间的数，用以选择哪些信息需要丢弃。随后再利用输入门计算  $i_t$  用以决定更新信息的量以及一个待选择的信息  $\tilde{C}_t$ ，最后计算出新的信息  $C_t$ 。输出门利用  $h_{t-1}$  和  $x_t$  计算需要的特征，结合  $C_t$  信息，输出最终的向量表示  $h_t$ 。该向量表示就可以代表整个文本的抽象特征，可以用来作文本分类任务。

### 2.5.4 BERT 模型

BERT<sup>[25]</sup> 模型是基于 transformer 模型<sup>[24]</sup> 提出的 自然语言处理领域的预训练




图 2-15 BERT 模型基础架构

模型。如图2-15所示，bert 主要结构采用了 transformer 的 encoder 部分，如图左所示。在每一个 encoder 结构中，文本单词向量首先经过一个多头注意力机制以及一个残差连接的标准化层（add & norm），之后在经过线性转化和又一个标准化层，将结果输入到下一层网络。如图右所示，bert 中由多个这样的 encoder 结构组成。BERT 预训练过程主要是随机遮盖或替换一句话里面任意字或词，然后让模型通过上下文的理解预测那一个被遮盖或替换的部分。

### 第三章 基于图模型的整体文本分类算法

由前两章介绍可以得知，文本数据由多个单词构成，每个单词可以视作单一的个体，单词之间又充满着联系，因此采用图模型建模文本数据，有利于分析单词之间的关联，进而有助于提升模型对文本结构、文本蕴意的理解，从而提升模型分析文本，理解数据的能力。因此，本章提出一个基于图模型理论的方法，将文本数据构建为图结构，从单词之间关联分析文本内容，实现文本分类任务，提升文本分类准确率。

#### 3.1 引言

近年来，图神经网络被广泛应用于学习图的局部和全局的丰富结构信息<sup>[6,47]</sup>，它引起了众多研究者的极大关注。文本数据并不是一种天然的图结构数据，需要人为的定义规则去构建图。Yao 等人<sup>[23]</sup>就提出了一种基于图模型的文本分类算法。他们首先根据语料库中词的共现情况以及文档与单词之间共现关系为边，构建了一个包含单词作为节点以及文档也作为节点的图。然后采用 GCN 学习单词以及文档节点的向量表示。该方法在测试数据集上展现了良好的性能。但是这个方法忽略了单词在句子中的顺序，同时由于整个语料库中单词表示仅有一个，忽略了单词在不同语境下可能具有不同的含义，最重要的一点即是构成的图是依据整个语料库构建的单一图，结构是固定不可更改的，因而图的大小取决于语料库的大小，语料库过大将会导致图模型难以计算，更难以扩展到新的文本数据中。

本章提出一个基于图卷积神经网络（GCN）的文本分类算法。具体来说，该算法为语料库中的每个文本构建一个图，不同于 Yao<sup>[23]</sup>的方法，仅使用单词作为节点，而不考虑文档作为节点。这样有助于捕获词之间在空间、时间和上下文中的信息。同时算法还为每个图创建一个连接到所有单词节点的“虚拟”超节点，它专门用作上下文感知组件，用于学习文档全局的特定信息。经过 GCN 学习后，获得了单词新的向量表示以及一个超结点的向量表示。超结点的向量表示可以视为文本数据全局信息表示。而对于新的单词向量表示，将其输入到一个卷积神经网络（CNN）用以学习文本数据中局部信息以及序列信息。最终，算法融合超结点向量信息以及 CNN 模型学到的向量信息，作为最终的文本向量表示，用以文本分类任务。

综上所述，本研究的主要特点有两个方面。①本章提出了一种基于图模型的文本分类方法，通过单词之间的关系构建图，通过图模型学习，从而进一步优化单

词向量表示。② 构建超结点学习文本的全局信息，结合 CNN 提取出的局部信息，相比于目前较为常用的方法，模型分类准确率有一定提升。本章第二节对整体文本分类任务问题进行阐述，第三节介绍算法的整体设计，第四、五节则对模型采用常用的数据集进行验证。

## 3.2 问题定义

本章主要研究的是对文本数据进行分类的算法。比如一个文本 “a very funny movie”，纵观整个句子，从 “funny” 这个词就能分析出这句话的情感是正向的，因此整个文本即可归为正向分类。整体文本分类算法是从具体整体含义出发，确定文本所属的某一类别。

某一文本数据  $T_i$  由一组  $n$  个单词构成， $T_i = [w_1, w_2, \dots, w_{n-1}, w_n]$ ，其中每个单词  $w_i$  都会有一个初始化的向量  $v_i$ ，向量可以是随机初始化，也可由各类单词向量表示学习方法获得。因此一个文本可以由一个  $\mathbb{R}^{n \times d}$  的向量矩阵表示，其中  $n$  表示文本中单词的个数， $d$  表示为单词向量的维度。文本分类任务就是学得一个函数  $F(\cdot)$ ，通过输入一个文本数据，然后得出该文本所属的类别，通过一个文本仅对应一个类别。比如根据一段新闻的描述，判断它是属于财经类新闻，还是娱乐明星类的新闻。

## 3.3 算法模型设计

传统的文本分类算法忽略文本在语料库中整体的统计信息，以及单词之间的互相影响。因为单词之间互有关联，尤其是同一个句子中的单词含义应该与整个句子的语义有关，而通常的单词嵌入模型每个词向量仅有一种。因此本章算法采用图模型将单词之间的信息通过图网络互相传递，重新学得更符合整个句子语义的单词的表示。同时还结合每个单词在整个语料库的统计信息，进一步生成代表整个文本含义的特征向量表示。对于单词向量继续采用常规的 CNN 模型进行分析，再与单词统计信息学的到特征向量相结合，最终实现文本分类任务。本节主要详细介绍算法模型，命名为 TextGraph。首先介绍了模型的整体设计，随后详细介绍每一步的具体实现及算法细节。

### 3.3.1 模型总览

本章实现的文本分类算法流程如图3-1所示。数据预处理主要是指自然语言处理前需要对文本数据进行统一的规则化处理，比如将所有文本都处理成小写字体，同时删除部分无关的词汇，如一些停止词等。建立词汇表，不同的单词应该对应

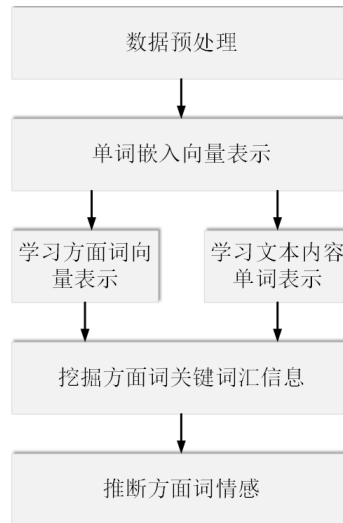


图 3-1 文本分类算法流程图

一个唯一的索引，有助于后期处理时正确找到每个单词所对应的嵌入向量。




图 3-2 TextGraph 模型

TextGraph 是一个端到端的模型深度学习模型，输入文本数据，输出文本的标签分类。该算法共有三个部分，如图3-2所示，第一部分定义为文本构图，即通过一些方法，将文本数据转化为图结构，转化为后面算法计算需要的数据。第二部分为单词向量表示学习以及 CNN 网络对文本特征提取，即采用图模型对构成的文本结构图进行学习，获取新的单词向量表示。对新的向量表示再采用 CNN 网络提出文本的特征，主要是局部特征。第三部分为向量信息融合及分类，通过前两步学习，可以获得一个超结点的向量以及经过 CNN 池化后的文本向量，两种向量从不同方面学习到了文本的信息，将两类向量进行融合提升模型准确率。以下几节将分别对这些部分进行详细介绍。



### 3.3.2 文本数据建模为图结构

TextGraph 将文本数据构建为一个带权的有向图，其中每个单词即为一个节点，边表示为单词之间的某种关系。同时，该算法创建了一个超节点，这个节点连接到所有的单词节点，同时采用特殊的计算方式构建边之间的权重。超节点可以理解为全局信息表示，再模型训练过程中，获取文本的整体信息，同时将这些信息传递给单词节点，使得单词节点信息表示更加丰富。图中节点的初始化属性即为单词的属性，这类属性通常由单词向量表示学习方法获得，例如 GloVe 方法<sup>[13]</sup>，有时也可以采用随机初始化的方式表示单词属性，如高斯分布下的随机初始化。




图 3-3 图构建过程

为了获得带权重的有向图，该算法采用了滑动窗口策略实现。滑动窗口的大小  $m$  是固定的，主要根据实验结果获得。该策略详细步骤如下。滑动窗口是对文本的单词进行滑动，每个窗口内根据窗口大小  $m$ ，包含  $m$  个单词。在窗口中，单词与单词之间构成一个单词对，前一个单词对于后一个单词具有权重  $w_f$ ，后一个对于前一个单词具有权重  $w_b$ ，其中  $w_f$  和  $w_b$  也是预先定义的固定大小的值，为了反映序列信息，通常这两个值不一样。因此滑动窗口大小  $m$  和权重  $w_f$  和  $w_b$  是可调节的超参数。滑动窗口依次从左向右移动一个单词距离。如果已经存在连接两个单词的边，则将累积相应的权重。这个过程不断迭代，直到滑动窗口覆盖了文本的最后一个单词。如图3-3所示，给定的文本序列是  $[w_1, w_2, w_3, w_4, w_5, w_3]$ ，其中每个  $w_i$  是一个单词。为了简单起见，将参数设置为  $m = 3$ 、 $w_f = 0.5$  和  $w_b = 0.1$ 。开始时，滑动窗口覆盖  $[w_1, w_2, w_3]$  这三个单词，因此构成了前向边  $w_1w_2$ ， $w_1w_3$ ，和  $w_2w_3$ ，每个权重均为 0.5。同时，后向边有  $w_2w_1$ ， $w_3w_1$ ，和  $w_3w_2$ ，其权重为 0.1。然后，滑动窗口向右移动一个单词，到达  $[w_2, w_3, w_4]$  这个序列。由于边  $w_2w_3$  已经存在，新的权重将变为  $0.5 + 0.5$ 。同样，对于边  $w_3w_2$ ，新的权重变为  $0.1 + 0.1$ 。此过程一直持续到最后一个窗口  $[w_4, w_5, w_3]$ 。单词  $i$  和单词  $j$  之间的累计权重由  $a_{ij}$  表示，该算法通过滑动窗口的总数来规范化  $a_{ij}$ ，计算方式为  $\frac{a_{ij}}{c}$ ，其中  $c$  为滑动窗口次

数。超结点则是连接到所有其他单词节点的一个虚拟节点，其边的权重由整个语料库中单词的 TF-IDF 计算得到。因此节点与节点之间的权重  $A_{ij}$  可以由公式3-1得到。

$$A_{ij} = \begin{cases} \frac{a_{ij}}{c} & \text{当 } i, j \text{ 都是单词时} \\ TF-IDF(i) & \text{当 } i \text{ 是单词, } j \text{ 是超结点时} \\ 1 & i = j \\ 0 & \text{其他情况} \end{cases} \quad (3-1)$$

因此，对于图3-3中的文本的邻接矩阵  $A$  可以如下公式3-2表示，该矩阵不包含超结点的权重信息。

$$A = \begin{bmatrix} 1 & 0.5/4 & 0.5/4 & 0 & 0 \\ 0.1/4 & 1 & 1/4 & 0.5/4 & 0 \\ 0.1/4 & 0.2/4 & 1 & 1.5/4 & 0.6/4 \\ 0 & 0.1/4 & 0.3/4 & 1 & 1/4 \\ 0 & 0 & 0.6/4 & 0.2/4 & 1 \end{bmatrix} \quad (3-2)$$

### 3.3.3 表示学习过程

文本分类效果取决于单词嵌入表示的学习以及文本表示学习过程，TextGraph 通过 GCN 网络重新学习到单词向量表示，再将学习到的向量表示输入到 CNN 网络结构中进一步提取特征信息，以达到最优的特征提取。

本章采用 GCN 网络去学习构建好的文本图数据。通过多层的 GCN，单词节点不仅能够获取与自己在同一窗口下的其他单词信息，也能获取得到得更远的单词信息。单词之间的信息可以通过构建好的边进行共享。而对于超结点，因为包含了语料库中单词的共现信息——通过 TF-IDF 方法获得到的，因此超结点在 GCN 网络学习的过程中，会获得整个文本的全局信息，同时这些信息也会选择性的传递给所有单词节点，以辅助单词节点学习到更加丰富的表示。同时，采用了注意力机制辅助模型在学习的过程中关注于重点信息。即有些单词之间虽然具有边，但是由于这些单词之间关联程度并不高，采用注意力机制有助于降低对不重要信息的关注，将更多注意力放在重点的单词节点上进行信息传递。因此对于单词  $i, j$  之间的注意力分数可以通过公式3-3得到。

$$\gamma_{ij} = \text{sigmoid}(x_i W_{a1}) + \text{sigmoid}(x_j W_{a2}) \quad (3-3)$$

$\gamma_{ij}$  即为注意力分数，其中  $W_{a1}$  和  $W_{a2}$  为  $d \times 1$  的权重矩阵， $x_i, x_j$  为当前单词  $i, j$  的向量表示，为  $1 \times d$  的向量。 $\text{sigmoid}$  为激活函数。加入注意力机制后，与形如公式2-8所示的 GCN 计算方式略有不同，对于每一层的单词向量表示计算可以由公式3-4,3-5,3-6计算得到。

$$H^l = \sigma((\gamma^l \hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}}) H^{l-1} W^l) \quad (3-4)$$

$$\hat{A} = A + I \quad (3-5)$$

$$\hat{D} = \sum_j A_{ij} \quad (3-6)$$

其中  $H^l$  为  $n \times d$  的矩阵，第  $i$  行的向量表示为文本序列中第  $i$  个单词的在 GCN 网络中第  $l$  层的向量表示，为一个  $1 \times d$  的向量。 $\gamma^l$  则为第  $l$  层计算得到的权重矩阵。

经过 GCN 网络学习后，每一单词向量都得到更新，获得了新的向量表示，假设第  $i$  个单词的输出向量为  $h_i \in \mathbb{R}^k$ ，其是一个  $k$  维的单词向量。因此对于一个包含  $n$  个单词的文本序列可以获得一个  $H \in \mathbb{R}^{n \times k}$  的矩阵，即  $H = [h_1, h_2, \dots, h_n]^T$ 。

为了得到文本的局部信息以及序列信息，本算法采用一个一维卷积神经网络 (CNN) 结构提取相关特征。其中 CNN 网络中的卷积核  $w \in \mathbb{R}^{h \times k}$  是一个  $h \times k$  的权重矩阵， $h$  表示为当前 CNN 网络的卷积窗口大小为  $h$ ，即每次窗口考虑  $h$  个单词用以计算特征值，计算公式如3-7所示。其中  $\sigma$  是一个激活函数， $b$  是偏置矩阵。

$$f_i = \sigma(w \cdot y_{i:i+h} + b) \quad (3-7)$$

文本数据的卷积操作不同于图像数据，只会在文本序列的一个方向做卷积，即在垂直方向做卷积。卷积核每次移动向下一个单词移动一次，如图3-4所示，红色线框为卷积核，每次计算生成一个特征值，之后向下移动一步，如虚线框所示。因此这样的卷积操作下，将会生成  $(n - h + 1)$  个特征值。




图 3-4 CNN 特征生成过程

对于每一个卷积核产生的一组特征值，为了获取其中最关键的特征，本算法采用最大池化操作进行特征提取。最大池化操作有助于选取最重要的特征，比如一句话“这个公园景色不错，但是我今天玩得并不开心。”，虽然这句话从前面的信息来看好像是正面的表述，实际上通观全文，最后的“玩得并不开心”的信息才是最重要的。通过选择每个卷积核中的提取的特征的最大值，可捕获其最重要的特征。这样操作后每一个卷积核得到特征就是一个值。另一方面，采用池化操作有助于降低参数量，进而可以减少模型过拟合问题。经过多个卷积核的卷积池化操作后，将这些所有卷积核产生的特征值拼接起来就能得到文本的特性向量表示。

### 3.3.4 向量融合及分类

经过以上步骤，将获得一个超结点的向量表示  $e_h$ ，这个向量可以理解为对全局信息的捕捉；以及经过 CNN 网络提取得到的文本向量表示  $e_c$ ，这个向量可以理解为对局部信息以及重点关注信息的表示。总之，这两个向量都可以作为文本的向量表示，只是包含的信息内容有所不同。 $e_h$  和  $e_c$  都可以单独作为结果实现文本分类。而两者的结合将会获得表示更加充分的文本向量。

本章，采用两个不同的线性变化层，将  $e_h$  和  $e_c$  向量转为与标签大小  $m$  同一维度，如公式3-8,3-9所示。

$$s_h = \text{softmax}(e_h \cdot w_{h1} + b_1) \quad (3-8)$$

$$s_c = \text{softmax}(e_c \cdot w_{c2} + b_2) \quad (3-9)$$

其中  $w_{h1} \in \mathbb{R}^{d_1 \times m}$  为  $d_1 \times m$  的参数矩阵,  $w_{c2} \in \mathbb{R}^{d_2 \times m}$  为  $d_2 \times m$  的参数矩阵.  $d_1$ 、 $d_2$  分别为  $e_h$  和  $e_c$  的维度大小。softmax 为激活函数，是将一组数值压缩到 0-1 之间，它们的和为 1，可以近似的看做是预测概率。对于分类任务而言，一个  $1 \times m$  的输出向量经过 softmax 计算后，每一位位置上的值可视作这个位置上对应的标签的概率。softmax 计算如公式3-10所示。

$$s = \frac{e_i}{\sum_j e_j} \quad (3-10)$$

经过以上公式计算得到了来至于超结点的预测结果  $s_h$  以及来自 CNN 的预测结果  $s_c$ 。为了平衡两者预测的影响，本节采用了一个超参数  $\alpha$  去控制，如公式4-17所示。 $\alpha$  取值在 0-1 之间。

$$O = (1 - \alpha) \times s_h + \alpha \times s_c \quad (3-11)$$

因此对于整个模型来说代价函数  $C$  可以由公式3-12得出。

$$C = -\frac{1}{M} \sum_x [(1 - \alpha)(y \ln a_h + (1 - y) \ln(1 - a_h)) + \alpha(y \ln a_c + (1 - y) \ln(1 - a_c))] \quad (3-12)$$

其中  $M$  表示为所有样本数,  $x$  代表一个样本,  $y$  表示当前这个样本的真实标签,  $a_h$  表示为超结点向量最终的预测结果,  $a_c$  表示为 CNN 提取的文本向量最后的预测结果。

### 3.4 实验设置

#### 3.4.1 数据集描述及数据处理

本章使用文本分类任务中广泛使用的一些数据集, 其中包括 R8、R52、MR、Yelp 等数据集。本章分别在这四种数据集上进行验证模型及与其他模型进行对比。

**R8 和 R52** 数据集是广泛被使用的一种用于文本分类任务的数据集, 其主要来自于路透社的新闻数据。因此其为英文文本数据集。对于 R52 来说总共有 6532 个训练集样本以及 2568 个测试集样本, 平均文本长度为 69.82, 共计 52 种分类类别。R8 数据集共计有 5485 样本用做训练集, 2189 个样本用作测试集, 平均文本长度 65.72, 共计 8 个不同的类别标签。以 R8 数据集为例, 其文本数据如 “us house speaker wright concerned of interest rate rise under greenspan”, 该文本数据对应的标签为 “interest”, 即对于 R8 数据集来说, 是对文本数据打上最符合的 8 种标签中的一个。

**MR**<sup>[48]</sup> 数据集是一种在每个文本序列中只包含一种情感的电影评论数据集。它包括 5331 个负面情感数据样本以及 5331 个正面情感的样本, 其平均长度为 20.39。本章中采用 Tang 等人<sup>[49]</sup> 使用的训练集测试集划分方式。MR 数据集中数据如 “the cast is phenomenal, especially the women” 所示, 其中这个文本对应的标签为 “1”, 即代表为正面情感。MR 总共两种情感, 数据集中分别用 “0”, “1” 分别表示负面情感和正面情感。

**Yelp** 也是一种评论数据集, 其标签是 1-5 之间的分数, 共计 5 种标签。为了平衡数据集划分以及控制文本数据集的长度, 本章对这类数据集中的所有数据进行随机抽取, 仅抽取文本长度在 150 个以下的, 最终共计获得 18972 个数据集样本, 其中包含 14000 个用作训练集, 4972 个用作测试集, 同时将平均文本长度在 81.17。取其中一个文本为例, Yelp 数据集文本如 “awesome mall all kinds of stores we dont have on the west side !!”, 这段文本对应的标签为 “4”, 即对于 Yelp 数据集来说, 每个文本都有一个在 1-5 之间的标签。

以上四种数据集详细统计如表3-1所示。

表 3-1 数据集数据统计

数据集	总文本数	训练集数	测试集数	单词数	类别数	平均长度
R8	7,674	5,485	2,189	7,688	8	65.72
R52	9,100	6,532	2,568	2,568	52	69.82
MR	10,662	7,108	3,554	18,764	2	20.39
Yelp	18,972	14,000	4972	26,889	5	81.17

本章中使用的均为英文数据集，因此不用考虑像中文分词。由于英文单词有大小写之分，例如希望在文本处理过程中将 “No” 和 “no” 视作是一个词，因此一般需要将所有的词都转化为小写。同时在文本中存在一些停用词，即许多对分类任务没有太大帮助的词语，比如 “aha”、“oh” 等，因此也将这些词语去掉。如句子 “No one wants to see this movie. Oh, it’s too bad” 经过预处理后变为 “no one wants to see this movie. it’s too bad”。对自然语言的文本数据，计算机是无法直接理解的，需要将其转化为计算机能够识别的数据。本章使用 Glove 作为词向量初始化输入。首先对于一个句子，采用 “空格” 作为分割，将一句话转化为单词列表，如上句子转为单词列表即为

[no, one, wants, to, see, this, movie, it's, too, bad]

同时根据整个语料库对所有的单词进行一个唯一编号，本章根据单词出现的顺序进行编号，每个单词均有一个数字作为唯一标识，如上句单词列表经过编号转化后，可能表示如下：

[4, 487, 3667, 34, 1, 555, 676, 12465, 376, 89]

每个编号同时还对应着一个维度为 300 的唯一的向量表示，来自于 Glove。例如单词 “no” 在 glove 中的向量表示如下：

[-0.015103 -0.618705 0.127657 0.020094 0.186504

...

0.032921 -0.153918 0.827338 -0.409457]

也即是编号 “4” 对应的向量如上。例如对于一个单词数量为 18764 的 MR 数据集，便有 18764 个对应的词向量。如果词向量不存在于 Glove 中，则采用随机初始化的方式生成。因此上述句子便能转为一个形如下的向量矩阵：

[-0.015103 -0.618705 0.127657 0.020094 0.186504

...

0.032921 -0.153918 0.827338 -0.409457]

[0.115103 -0.612235 0.432126 0.045531 -0.488512

...  
 -0.132921 0.148618 0.395361 0.642315]  
 ...  
 [0.515103 -0.122212 0.007217 0.123204 -0.076414  
 ...  
 0.102212 -0.000123 0.464318 0.100671]

最后这样的一个单词矩阵就可以作为计算机可以识别的输入。

### 3.4.2 对比方法介绍

本章提出的方法是用于实现整体文本分类任务，即一个文本对应一个标签类。因此，所对比的方法都是用于该文本分类任务，且均采用 Glove 词向量作为单词的初始化向量。所涉及比较方法均属于深度学习模型，且是目前广泛使用的自然语言处理模型。比较模型主要包括以下：

**LSTM：**是一种特殊的 RNN 模型，可以解决长序列训练过程中的梯度消失和梯度爆炸问题，相比于普通的 RNN 模型，具有更优异的表现。LSTM 每一个循环中，对于输入的单词向量均会产生一个隐藏向量表示，本章中将这些生成的单词的隐藏向量表示做一个平均池化作为文本的向量，用于实现文本分类任务。

**Bi-LSTM<sup>[18]</sup>：**是一种双向的 LSTM 模型。它将一个句子从前到后进行处理，同时对句子从后到前进行编码，最后将两种信息拼接起来。相比于 LSTM 多了一个从后到前的信息，这样的设计有利于模型进行更细粒度的理解，更好的捕捉双向的语义依赖。本章中采用 LSTM 获取文本向量的方式，对通过前向 LSTM 获得的文本向量以及从后向 LSTM 获取的到的文本向量进行拼接，作为最终的文本向量表示，以用于分类任务。

**TextGCN：**TextGCN<sup>[23]</sup> 将单词和文档视作图中的节点，通过 GCN 进行半监督学习单词节点和文档节点的向量表示，这些节点使用 one-hot 向量进行初始化。学习到的文档节点表示即可直接用于实现文本分类任务。

**TextCNN：**本章采用由<sup>[19]</sup>提出的 CNN 处理文本的方法。对比实验采用一维卷积，对于卷积后的特征值采用最大池化的方式挑选最重要的特征值。多个卷积核生成多个卷积池化后的特征，将这些特征拼接作为文本向量表示，实现文本分类任务。

**RCNN：**Lai<sup>[20]</sup>等人提出一种将循环神经网络与卷积神经网络中的特点相结合的方法。它首先通过 RNN 网络获取文本信息，然后采用 CNN 中的池化操作提取这些信息中的重要部分。最终获得表示文本的向量，用以实现文本分类任务。

**MLP:** 作为最基本的神经网络对比方法, 本章中将一个文本中的所有词向量进行拼接, 然后将获得的向量输入一个仅包含输入层、隐藏层和输出层的神经网络实现文本分类任务。

**HAN:** Hierarchical Attention Networks<sup>[50]</sup> 是一种结合了双向 RNN 和注意力机制的神经网络模型。这个模型关注单词之间的关系, 同时也关注句子段与句子段的关系。即它将一个句子分为多段, 在每一段中首先将单词输入双向 RNN 网络中获得每个单词的隐藏向量表示, 之后采用注意力机制将这些单词向量进行加权和获得当前句子段的向量表示。对每一个句子段均采用这种方式学习向量表示。多个句子段获得多个向量表示, 再采用双向 RNN 网络学习这些向量的新的向量表示, 最后将这些学到的句子段向量表示使用注意力机制结合成一个单一的向量, 用以表示文本的向量, 用作文本分类任务。

**TextGraph-CNN:** 本章提出的方法主要结合了超结点的向量以及 CNN 提取的向量, 因作为对比验证, 仅使用 CNN 提取后的特征向量作为最终的文本向量表示, 用以分类, 不再结合超结点的向量。

**TextGraph-HN:** 与 TextGraph-CNN 类似, 作为对比, 仅使用超结点向量作为文本向量表示。

### 3.4.3 模型训练及验证

对于所有的对比方法以及本章提出的方法均使用来自于 GLove 的 300 维预训练单词向量作为初始化, 同时均采用相同预处理方式得到的文本数据集。均采用 Adam<sup>[51]</sup> 优化器对模型进行训练更新权重, 且所有模型的学习率都设置为 0.001。所有模型都采用相同的超参数, 即使用相同大小的隐藏层神经元, 本章中均设置为 128。对于 HAN 网络, 本章中设置将一个句子划分为 3 段。对于 TextGraph 模型, 本章将单词建模过程中的窗口大小设置为 4, GCN 网络层数为 2, 采用的 CNN 网络中的卷积核大小与对比方法 TextCNN 中采用的卷积核一致, 均使用 3, 4, 5 大小的卷积核, 同时每种大小的卷积核都有 128 个。所有模型训练中都采用 dropout<sup>[52]</sup> 值为 0.5 防止网络训练过程中的过拟合问题。

为了测试模型之间的性能, 所有数据集均划分为训练集和测试集, 模型在训练集上进行训练, 在测试集上进行验证。

为了验证模型对于随机初始化向量的学习能力, 即在不依赖预训练单词向量的前提下, 是否依然具有良好的分类性能。实验中不采用 Glove 方法中获取得到预训练向量, 而是采用高斯分布随机生成 300 维的向量用做单词向量的初始化。所有模型在训练集中通过反向传播更新单词向量表示, 测试时直接采用训练过程



中学到的单词向量表示作为输入进行验证。

为验证模型在少量训练集的情况下的学习能力，本章中采用挑选 R8 数据集中的部分训练集数据作为模型训练的数据。挑选比例分别设置为 2.5%，5%，7.5%，10%，12.5%，即训练样本数分别为 137，274，411，548，685，其余所有的数据集则作为测试集验证模型的性能指标。

模型分类性能影响可能来自于学习到的向量表示之间是否有较为分明的界限，因此本章中挑选 R8 数据集文本向量学习结果，采用 2 维的 t-SNE 方法实现可视化。本章对比了 LSTM 模型和 TextGraph 之间的可视化差异。

#### 3.4.4 实验评价指标

因为文本分类主要是多分类任务，本章中主要采用准确率（accuracy）和 macro-F1 分数来验证模型的性能。对于了解这些评价指标首先得了解 TP（True Positive）、TN（True Negative）、FP（False Positive）、FN（False Negative）。

**TP:** 即真实的正样本。

**TN:** 即真实的负样本。

**FP:** 即假的的正样本。

**FN:** 即假的负样本。

因此对于二分类的准确率（accuracy）计算如公式3-13所示。

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3-13)$$

由于本章涉及的均为多分类，因此准确率（accuracy）计算方式可以归纳为如公式3-14所示， $T$  表示为所有预测正确的样本数， $F$  表示为所有预测错误的样本数。

$$accuracy = \frac{T}{T + F} \quad (3-14)$$

另外精确率（Precision） $P$  和召回率（Recall） $R$  的计算方式分别为公式3-15、公式3-16所示。

$$Precision = \frac{TP}{TP + FP} \quad (3-15)$$

$$Recall = \frac{TP}{TP + FN} \quad (3-16)$$

而计算 macro-F1 分数需要由 macro-Precision 和 macro-Recall 得到，计算方式如公

式3-17、公式3-18、公式3-19所示，其中  $P_i$ ,  $R_i$  分别表示标签  $i$  的精确率和召回率。

$$macro - Precision = \frac{1}{D} \sum_i P_i \quad (3-17)$$

$$macro - Recall = \frac{1}{D} \sum_i R_i \quad (3-18)$$

$$macro - F1 = \frac{2 * macro - Precision * macro - Recall}{macro - Precision + macro - Recall} \quad (3-19)$$

本章设置的对比实验中均采用准确率（以下简称 ACC）和 macro-F1 分数（以下简称 F1-score）这两个指标来进行展示与分析。

### 3.5 实验结果及分析

#### 3.5.1 模型分类性能分析

本小节主要比较了采用 Glove 预训练的词向量初始化以及采用随机初始化的模型之间的差异。

如表3-2所示，展示了采用 Glove 预训练的模型的准确率（ACC）和 F1 分数（F1-score），可以明显看出本章提出的模型在所有数据集上均取得了最优的分类结果。

表 3-2 采用预训练词向量下的各模型分类性能比较

Models	MR		R52		R8		Yelp	
	ACC	F1-score	ACC	F1-score	ACC	F1-score	ACC	F1-score
TextGCN	76.74	76.72	93.56	65.51	97.07	92.41	-	-
TextCNN	78.16	78.16	93.90	67.37	97.24	92.57	51.52	45.15
HAN	77.78	77.67	<u>94.64</u>	<u>74.62</u>	97.15	93.62	53.51	48.91
LSTM	78.06	77.99	91.86	64.32	96.66	89.58	<u>54.88</u>	<u>51.67</u>
Bi-LSTM	<u>78.55</u>	<u>78.55</u>	93.22	64.95	96.71	91.79	54.08	49.92
RCNN	78.09	78.04	93.55	65.27	<u>97.65</u>	<u>94.64</u>	53.57	47.97
MLP	72.22	72.19	86.48	37.90	95.61	83.39	46.60	39.52
<b>TextGraph</b>	<b>80.19</b>	<b>80.19</b>	<b>95.33</b>	<b>78.55</b>	<b>98.03</b>	<b>95.48</b>	<b>55.31</b>	<b>51.80</b>

对于 MR 数据集来说，本章提出的放在无论在 ACC 上还是 F1-score 上均表现了最优的结果，而作为对比方法 Bi-LSTM 展现了出除本章提出的算法外最好的效果。分析来看，主要是 MR 数据集是属于情感分析类数据集，分类标签与情感相关，因此文本中的词序对情感分类具有较大的影响，尤其是一个单词的情感语义

既有可能受前面的单词影响，也有可能受后面单词的影响。而 Bi-LSTM 采用一个前向的 LSTM 以及一个后向的 LSTM 分别捕获单词之间前后的依赖关系，因此对于同样采用了双向 RNN 结构的 RCNN 来说，分类效果也不错。但是 HAN 却低了一截，主要原因可能是 HAN 将一个句子分为多段，对于 MR 数据集来说，其句子平均长度相对较短，仅只有 20.39，因此在短句子情况下进行分段可能会影响模型性能。本章提出的方法，在构建图的过程中采用了前后单词权重不同的方式构图，即双向边根据单词出现的前后关系具有不同大小的权重，在一定程度上考虑的单词之间的先后顺序，因此该算法展现了一定的效果。而对于 textGCN 来说，其完全忽略了单词之间的顺序，因此效果较差，没有在 MR 数据集上取得好的分类性能。

从在 R52 数据集上的实验结果来看，LSTM 和 Bi-LSTM 模型的性能都比 TextCNN 差。这主要是由于 R52 属于新闻分类数据集，决定该数据集分类类别的主要因素是一些关键的单词，这些单词决定了文本的类别。此时文本的语序反而不是那么重要了。RNN 模型更多的关注于文本的时间序列信息，在捕获序列顺序相关信息时存在一定优势，但是对于这种关键特征的提取不如 CNN 模型。TextCNN 可以通过不同大小的卷积核对文本中的关键词，关键信息进行提取，捕捉单词之间的潜在关系，再通过池化操作实现对最重要的特征筛选。R52 数据集长度适中，且注意力机制依然可以通过模型训练达到对重要信息的关注，因此采用了注意力机制的 HAN 模型在 R52 数据集上展现了很好的分类性能。本章提出的方法因为使用了窗口滑动的方式实现单词之间边的建立，这样的处理方式类似于 CNN 卷积窗口，着重关注几个单词之间的联系，再加上注意力机制进一步捕捉重点信息，同时该模型最后再次使用了 CNN 对文本信息中关键特征进行提取，多种操作的结合，使得模型能够关注文本序列中对分类有重大帮助的词汇，进而加强分类效果。R8 数据集与 R52 数据集的实验结果类似，在使用了 CNN 结构或者注意力机制的模型上效果更好，如 RCNN，TextCNN 采用了 CNN 结构，HAN 模型采用了注意力机制，分类准确率都高于 LSTM, Bi-LSTM。由于 R8 数据集与 R52 数据集一样，都是来自于路透社的新闻数据，因此具有类似的性质。

在 Yelp 数据集的实验过程中，由于 Yelp 数据集单词数以及文档数相对较多，对于 textGCN 模型方法提供的构图方式需要将所有的单词以及所有的文档都作为图中的节点，进而产生的图过于庞大，导致本章使用的服务器无法运行，因此对于该方法的实验结果暂无法得到。这也是 textGCN 的一大缺陷，即当语料库相对较大时便无法运行。对于本章提出的基于 GCN 的模型，是针对每个文本进行构建一个小型的图结构，因此形成的图大小只取决于文本长度而不依赖于语料库大

小, 相比于 textGCN 大大降低了计算成本。且可以对新文本实现分类, 而 textGCN 实现分类的文本必须提前建立在图结构中, 当有新数据到来时无能为力。从实验结果来看 TextGraph 依然取得了最好的分类结果且明显高于其他模型方法。但是 LSTM 反而取得了其他模型中最优的实验结果。使用了双向 LSTM 的模型例如 HAN、RCNN、Bi-LSTM 都不如普通的 LSTM 效果好, 究其原因可能是由于 Yelp 数据集属于评论数据集, 一段文本中可能包含了不同的评价, 例如数据集中这句话 “not too impressed with the food , luckily we were with great friends so we had a fun time”, 分类标签为 “3”, 即 3 分。句子前面的情感色彩为较低, 后面的情感色彩偏高, 因此从单一方向阅读过去能够分析出中等的评价。虽然双向的 LSTM 能够捕捉反向的信息, 但是也有可能后面的情感色彩影响到了模型对前面句子的情感分析, 因而双向 LSTM 分类性能有所降低。

如表3-3所示展示了采用高斯分布随机初始化单词向量的分类效果。由于注意力机制需要两个单词向量计算, 随机初始化的单词向量会造成一定干扰, 因此本表中 TextGraph 方法去掉了注意力机制计算权重, 其他计算过程一致。从结果上来看, TextGraph 依然在大多数数据集上取得了最优的效果, 结果表明, 该方法在学习单词嵌入表示上具有一定优势。与采用预训练单词向量的结果相比, 大多数模型在 MR 数据集上表现并不好, 且下降明显。这可能是由于 MR 数据集训练集文本较短且样本相对较少, 而单词数却非常多, 这就导致了每个单词出现次数较少, 模型难以学到优异的单词的向量表示, 从而在测试集上效果不突出。

表 3-3 随机初始化单词向量各模型性能比较

Models	MR		R52		R8		Yelp	
	ACC	F1-score	ACC	F1-score	ACC	F1-score	ACC	F1-score
TextCNN	72.81	72.81	92.03	62.54	<u>97.18</u>	<b>92.27</b>	51.18	44.96
HAN	70.25	70.25	90.58	58.43	95.68	88.60	50.91	45.79
LSTM	73.29	73.29	90.39	59.22	96.32	83.82	<b>54.42</b>	<b>51.18</b>
Bi-LSTM	<u>74.17</u>	<u>74.13</u>	91.64	62.37	96.32	88.90	53.57	<u>49.07</u>
RCNN	73.77	73.77	<u>93.35</u>	<u>67.22</u>	97.09	<u>92.01</u>	53.47	47.13
MLP	64.51	64.45	80.62	30.05	89.06	60.41	41.23	28.71
<b>TextGraph</b>	<b>74.47</b>	<b>74.47</b>	<b>94.54</b>	<b>75.05</b>	<b>97.35</b>	91.75	<u>54.24</u>	<u>49.07</u>

为验证 TextGraph 的 CNN 结构和超结点结构的效果以及两者结合后的提升效果, 本章测试了 TextGraph-CNN 和 TextGraph-HN 两种结构在不同数据集情况下的分类性能, 前者是仅考虑 CNN 提取后的文本向量, 后者是仅考虑超结点得到的文本向量。如图3-5、图3-6 图3-7和图3-8所示, 主要展示了所有的对比方法中最优的分类结果以及本章提出的方法的分类结果。可以看出 TextGraph-CNN 在大多数数

据集下基本都高于对比方法中最优的模型，且在准确率在 MR,R52,R8,Yelp 数据集上，分别高于 TextCNN1.3%，0.8%，0.34% 和 2.97%。这两者方法中的 CNN 结构采用相同的参数设置，即相同的卷积核，相同的池化操作，TextGraph-CNN 明显高于 TextCNN。说明，该模型在学习单词嵌入表示上具有一定优异的能力，能够学到表征能力更强的单词向量，提升模型分类性能。TextGraph-HN 在大多数数据集上展现与 TextGraph-CNN 差不多的性能，只是在 MR 数据集上表现更差。两者的结合可以看出效果得到进一步提升。这是由于模型从局部特征以及全局特征进行了综合考量，从多个角度对文本进行分析，提升了整体的分类性能。




图 3-5 MR 数据集 ACC 和 F1-score




图 3-6 R52 数据集 ACC 和 F1-score

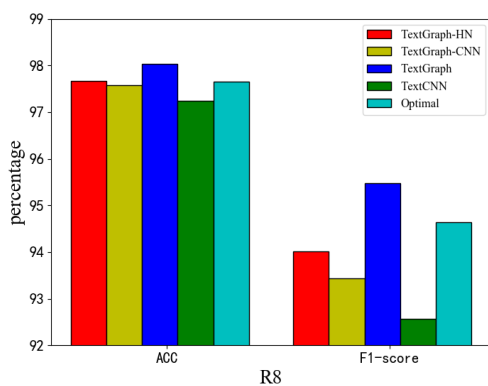


图 3-7 R8 数据集 ACC 和 F1-score




图 3-8 Yelp 数据集 ACC 和 F1-score

### 3.5.2 训练集比例的影响

为了了解训练集大小对模型文本分类性能的影响，本章从 R8 的训练集中随机选取了 2.5%、5%、7.5%、10%、12.5% 等不同百分比的样本作为训练集，其他的均作为测试集来评价训练模型分类性能。如图3-9和图3-10所示，展示了不同

比例下的模型分类准确率和 F1 分数。从图上可以看出，TextGraph 即使在低比率的情况下依然高于所有对比方法。TextGraph 在训练样本数为 2.5% 的情况下获得 91.9% 的准确率，而大多数基线的准确率低于 85%，仅有同样采用了 GCN 模型的 textGCN 与本章提出的方法差距不大。此外，TextGraph 的 F1 得分为 74.71%，而 TextCNN 的得分为 36.82%。这些结果表明，与 textGCN 采用了语料库中的信息类似，TextGraph 的文本图中的超节点能够捕获全局信息，以及语料库中的潜在信息——主要是通过 TF-IDF 得到的，另一方面文本图的构造方式能够很好地反映短文本的结构，可以作为一些人为定义的潜在知识。这些信息的结合，使得模型在低比例训练集情况下依然能够展现较为良好的性能。




图 3-9 不同比例训练集分类 ACC




图 3-10 不同比例训练集分类 F1-score

### 3.5.3 文本向量可视化分析

为了更好的理解 TextGraph 的分类性能，本章采用基于 t-SNE 的方法将不同模型生成的文本向量压缩至二维平面进行可视化观察。如图3-11所示，展示了采用 LSTM 模型进行训练的 R8 数据集的文本向量，该实验室采用 5% 的比例训练集进行训练，然后对测试集上的数据进行可视化分析。图中的每一个点代表了一个文本向量压缩后的向量表示。相同的颜色代表这个文本属于同一个分类标签。从图中可以看出即使是同一类的样本，也未能完全聚集在一起，且明显成“条状”，与其他类型的样本交错在一起。在同一个类别簇下，也杂含了许多其他类别的样本，界限并不分明。如图3-12所示，展示了采用 TextGraph 模型经过同样比例训练集训练后的测试文本向量。相比于 LSTM 的方法，该模型生成的同一类别的向量表示更加紧凑，不同类别之间的界限更具分明。如 LSTM 模型生成的样本中，蓝色和橘色样本交织在一起，这样对于分类来说难以区分它们，而本章提出的模型，这两种类别区分明显仅有少量的样本交错，这样便有较高的区分度，使得模型分类

准确率更高。




图 3-11 LSTM 模型的 R8 文本数据集可视化




图 3-12 TextGraph 模型的 R8 文本数据集可视化

### 3.5.4 本章小结

本章提出了一个基于图网络的文本分类模型，为序列相关的研究提供了一点另类的思路。方法首先对文本进行建模，对每一文本根据单词之间的先后顺序构建了一个独立的图结构。同时采用语料库中单词与文本的关联构建了一个链接文本中所有单词的超节点，用以捕获文本的全局信息以及语料库中的部分关联信息。将构建好的图输入到 GCN 网络中学习，这些步骤的实现都能促进模型学到更好的单词表示。之后再采用 CNN 模型对新的单词向量进行局部信息以及关键信息的捕捉。与其他常用的模型相比，本章提出的方法在准确率和 F1 分数上均有提升。同时在低比例训练集的情况下也能展现良好的性能。

## 第四章 基于图模型的方面级情感分析算法

第三章探讨了基于图模型理论的整体文本分类算法，图模型应用于文本分类任务取得了一定效果。尤其是考虑作为全局信息而引入的超节点对模型性能有一定的正面影响。超节点实际上不仅仅可以作为全局信息而使用，根据不同任务可以设置不同类型的超节点。本章依旧基于图模型理论，探讨关于方面级情感分析的任务。本章算法超节点不再使用全局信息而使用方面词信息，并与第三章构图方式一致，建立文本图结构，实现方面级情感分析。

### 4.1 引言

方面级情感分类<sup>[53]</sup>已经越来越备受关注，相比于一般的文本分类算法具有更高的实用性。例如对于在美团、京东、天猫等平台上进行的商品评价描述，采用方面级的情感分类可以针对商品不同的方面进行评价，进而实现对产品全方位的点评，并且平台可以根据点评的方面以于分类，以保障用户对不同方面的感知和需求。比如有些用户看重服务，有些用户看重质量。同时商家可以根据用户对不同方面的评价进行改进，提升商品整体质量。方面级情感分类相比于一般的文本分类算法，具有一定难度。

Li 等人<sup>[54]</sup>使用一个 Bi-LSTM 模型处理文本序列，获取每个单词的中间隐藏状态的向量表示，随后每个单词向量对应一个 CPT 结构（Context-Preserving Transformation）。每个 CPT 中采用 Bi-LSTM 模型学习一个方面词对应的信息向量然后与输入的单词向量拼接获取一个新的单词向量，该向量体现了每个单词与目标词之间的关系信息。通过 CPT 层后，每个单词具有一个新的向量表示，再对这组向量表示采用 CNN 模型卷积处理，捕捉关键信息，生成表示文本的向量，用以实现分类。Wang 等人<sup>[55]</sup>提出了一个基于 LSTM 的注意力机制模型。它将方面词的向量表示分别与文本内容的每个单词向量表示进行拼接，组合成新的向量，作为 LSTM 模型的输入。随后将 LSTM 模型获得的每步单词的隐藏状态与方面词向量用一个注意力机制求得权重，代表了每个单词对目标情感的贡献度。最后通过向量加权和表示最终的用以分类的向量表示。虽然这些方法取得了一定效果，但是使用不能并行计算的 LSTM 模型，计算效率相对较低。同时方面级的目标词与文本内容单词之间应该存在许多联系，如果能够挖掘它们之间的内在关系，便能进一步学到情感信息。

本章基于第三章提出的图模型算法，进一步改进使之适合方面级情感分析任



务。具体来说，本章的算法不再使用依据语料库信息构建超节点，而是使用对应的方面词构建，即希望这个超节点学习到的是方面词信息，同时将这个信息通过图结构传递给其他单词节点。文本图其他部分构建过程采用第三章描述的方式一致。考虑到门控机制具有选择遗忘的功能，而图卷积神经网络每一层的节点信息对于下一层并不一定都有用，因此，本章采用一个门控机制去控制每层节点信息的流动。通过图模型学习，将获得每个单词新的向量表示以及一个表示为方面词的信息向量。方面词的具体情感信息取决于文本中对应位置的情感词汇，因此，本章继续采用一个注意力机制，通过方面词向量去查询所有单词中对它情感偏向最重要的词汇，获得相应的权重，最后将这些向量进行加权和，得到最终的用以实现分类任务的向量。

综上所述，本章提出的方法主要有以下三点特色：①采用一个超节点表示方面词信息，并将这个信息通过图网络进行传递，进而捕捉文本单词以及方面词之间的关系，学到两者的向量表示。②通过门控机制选择或遗忘传递给图模型中下一层的信息。③利用注意力机制寻找对目标词情感贡献最大的词汇。

## 4.2 问题定义

本章主要探讨的是方面级情感分类任务。对于这类任务不同于整体文本分类任务，每个文本中都有一个或多个方面词。如句子“great food but the service was dreadful”，这个句子中定义了两个方面词一个是“food”，另一个是“service”，方面级情感分类任务的目标就是判断这两个方面词对应的情感倾向。如“food”这个词，采用“great”进行形容，是一个褒义词，因此对于“food”的情感可以归属于正向的。而对于“service”这个词，是使用“dreadful”进行描述的，属于贬义词，因此情感归属于负面。

某一文本数据  $T_i$  由一组  $n$  个单词以及多个方面词构成， $T_i = [w_1, a_i \dots a_j, w_{n-1}, w_n]$ 。其中  $w$  表示一个单词， $a_i$  表示为第  $i$  个方面词，通常方面词由一个或多个单词组成。文本中每个单词都有一个对应的单词向量，本章采用的单词向量主要是从 Glove 或经过 BERT 模型后得到。因此一个文本可以由一个  $\mathbb{R}^{n \times d}$  的向量矩阵表示，其中  $n$  表示文本中单词的个数， $d$  表示为单词向量的维度。方面级情感分类任务就是学得一个函数  $F(\cdot)$ ，输入这段文本以及需要分析的这段文本中的方面词，输出这个方面词对应的情感倾向，即判断这个方面词是正向的或是负面的或是无情感。

### 4.3 算法模型设计

以前的一些研究仅仅直接对方面词的向量以及文本向量进行拼接，并未细致考虑方面词与文本中其他单词之间的联系。如果能够挖掘它们之间的内在关系，便能进一步提升模型性能。此外在图卷积网络计算中，网络层数的增加意味着当前节点将会获取到更远处节点的信息。而更远处节点的信息不一定对当前节点有用，因此本章采用一个门控机制，选择性的选择或是遗忘节点信息，控制信息流动，进一步提升模型性能，确保学到更有效的向量表示。注意力机制使得模型关注于重要信息，查找对于方面词情感分析更为重要的词汇。本节主要详细阐述了算法模型，命名为 GAGCN，首先介绍了模型的整体设计，之后再详细介绍每一步的具体实现。

#### 4.3.1 模型总览

本章实现的方面级情感分析算法流程图如图4-1所示。预处理是指对文本数据进行统一的规则化处理，首先将所有文本都处理成小写字体，同时删除部分无关的词汇，比如一些停止词等。建立词汇表，不同的单词应该对应一个唯一的索引，有助于后期处理时正确找到每个单词所对应的嵌入向量。同时需要标注每个文本中对应的方面词所在位置，便于后续分析任务使用。方面词向量以及文本单词向

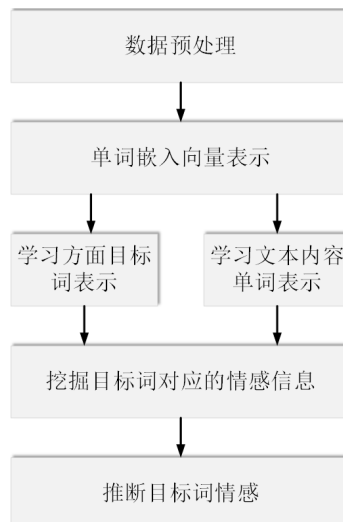


图 4-1 方面级情感分析算法流程图

量的学习都是基于图网络模型，经过图卷积神经网络学得到一个超节点向量，即表示为方面词向量，以及每个单词的新的向量表示。方面词关键词汇信息挖掘即使用注意力机制关注重点词汇，找出对该方面词的情感倾向有帮助的词汇，最后实现分析。

本章提出的方法是一个端到端的深度学习模型，即输入文本内容和对应的方面词，就可得到该方面词对应的情感类别。该算法总共有三个部分，如图4-2所示，第一部分定义为文本构图部分，该步骤主要是将文本中的单词采用第三章提到的构图方法构建成图，其次构造一个传递方面词信息的超节点。第二部分主要是单词词向量表示学习以及超节点的表示学习，这部分采用基于多头注意力机制的 GCN 进行学习以及一个门控机制用以控制图网络模型中每一层信息的传递。第三部分是基于第二部分学到的文本词向量以及超节点向量来计算。将超节点向量作为注意力机制中的 Query 向量，计算文本单词中所有单词的权重，权重的大小即可视作这个单词对方面词情感的分析的重要程度。随后将注意力机制获得向量与超节点向量进行一个简单地结合，即得到最终的分类向量，将这个向量输入一个简单的神经网络通过 softmax 激活函数实现情感分析任务。以下几节将对这些部分进行详细介绍。




图 4-2 方面级情感分析算法模型

### 4.3.2 文本图建模过程

本章文本图的构建过程与第三章图构建过程一致，均是采用滑动窗口的方式构建单词与单词之间的图。但与第三章略有不同，第三章中每个单词在图中仅有

一个节点，即使一个单词在同一个文本中只出现了一次，也仅仅视作一个节点。而本章中因为同时还要采用 BERT 预训练模型，因此构图过程中，为文本中每一个单词都构建一个节点，即使是同一个单词只要出现的位置不同，均构建一个不同的节点。单词与单词之间的边如第三章公式3-1所示。超节点不再使用 TF-IDF 的方式计算，构建的超节点依然是一个双向边，一向由方面词节点连向超节点，一向由超节点连接方面词。如图4-2所示，图中  $w_3w_4$  是属于方面词  $a$  的两个单词，超节点分别构建一条连接这两个单词节点的边，如图中虚线所示。构建时边的权重为固定值 1，在图卷积计算过程中会由注意力机制更新权重，着重关注于方面词中重要的词汇。超节点中双向边的构建有助于超节点向量传递给方面词中的每个单词，超节点向量可以视作整个方面词的信息，通过把完整的信息传递给其中的每个单词节点，有助于方面词中单词信息理解的完整度。其次，在多层的图卷积过程中，超节点信息也能进一步传递给其他单词节点，使得其他节点也能获得方面词向量信息。这样有助于整个文本向量理解任务目标，明确需要分类的具体方面词，进而有目的性的去学习有用的词向量。

#### 4.3.3 词向量与超节点向量表示学习

表示学习过程依然采用图卷积神经网络进行。相比于第三章提出的方法，在注意力机制计算过程进行了改进，同时还提出一个门控机制对每层传递的信息进行控制。如图4-3所示，假设在每一层 GCN 网络中，当前需要计算的节点向量为




图 4-3 方面级情感分析算法模型

$h_1$ ，它的邻居节点向量分别是  $h_2$ 、 $h_3$ 、 $h_4$ 、 $h_5$ 。为了选择最当前节点最重要的邻居节点，本章中采用多头注意力机制去计算，获取不同邻居节点对当前节点的权重。首先，当前节点的向量及其邻居节点向量经过一个线性变化得到注意力机制中的

$q$ 、 $k$  向量，每个向量的计算过程如公式4-1和公式4-2所示。其中  $W_Q$  和  $W_K$  均是一个维度大小  $d \times n$  的参数矩阵。

$$q = W_Q h_i, W_Q \in \mathbb{R}^{d \times n} \quad (4-1)$$

$$k_i = W_K h_i, W_K \in \mathbb{R}^{d \times n} \quad (4-2)$$

本章计算方式中查询向量  $q$  是指当前节点向量  $h_1$  变换后得到，而对于  $k$  向量是当前节点以及当前节点的所有邻居节点的线性变换，因此对于这些节点得到一个  $d \times m$  的矩阵  $K$ ，其中  $d$  为向量维度大小， $m$  是指节点个数，如图4-3所示， $m$  为 5。于是可以得到每个节点对应的注意力分数  $\alpha_i$ ，计算公式如4-3所示。其中  $leakyRelu$  是一种激活函数。计算方式如公式4-4所示， $c$  是一个超参数，通常取 0.001。

$$\alpha_i = \frac{\exp(leakyRelu(q^T k))}{\sum_j \exp(leakyRelu(q^T k))} \quad (4-3)$$

$$y_i = \begin{cases} x_i & x_i \geq 0 \\ \frac{x_i}{c} & x_i < 0 \end{cases} \quad (4-4)$$

再将所有节点的向量输入一个线性变换得到  $v$  值，计算方式如公式4-5所示，其中  $W_K$  是一个  $d \times n$  大小的参数矩阵。 $tanh$  为激活函数。因此经过注意力机制更新后得到当前节点新的向量表示为  $v'$ ，如公式4-6所示。因为本章使用多头注意力机制，因此有多个注意力计算参与，其中线性变换参数均有不同，因此最终该节点的向量表示应该为  $h' = concat(v'_1, v'_2, \dots, v'_t)$ ，其中  $t$  代表  $t$  头注意力机制。

$$v_i = tanh(W_V h_i), W_V \in \mathbb{R}^{d \times n} \quad (4-5)$$

$$v' = \sum_j v_j * \alpha_j \quad (4-6)$$

考虑到多层的 GCN 网络，每增加一层的计算，当前节点便会获取到更远邻居的信息，而远处节点的信息不一定对当前节点有用，同时还可能导致信息平滑问题，即当层数深且图较小时，同一连通分量内的节点的表征会趋向于收敛到同一个值<sup>[9]</sup>。这是由于一方面当前节点容易过多的吸收其他邻居节点的信息而损失了自身节点信息，另一方面层数加深后，当前节点会获取到更广泛的其他节点信

息，这就导致不同节点可能会收到相同的一组邻居节点的信息，使得信息趋于相同。已有部分工作用以解决这种问题<sup>[56,57]</sup>。本章采用门控机制，利用 GRU 中的一个更新门和一个重置门去处理这种问题。首先将 GCN 网络每一层中当前节点经过注意力机制更新后的向量  $h'$  即如图4-3中的向量  $h'1$  和当前节点处理前的向量  $h$  即如图4-3中的向量  $h1$  进行拼接，得到  $h_c$ ，如公式4-7所示。

$$h_c = \text{concat}(h', h) \quad (4-7)$$

之后将这个向量分别输入到更新门和重置门，计算过程如公式4-8和公式4-9所示。其中  $z_t$  和  $r_t$  分别表示更新门和重置门。 $W_{z_t}$ 、 $W_{r_t}$  分别为更新门和重置门的参数矩阵。 $\text{sigmoid}$  为激活函数，取值为 0-1 之间，计算如公式4-10所示。

$$z_t = \text{sigmoid}(W_{z_t} h_c) \quad (4-8)$$

$$r_t = \text{sigmoid}(W_{r_t} h_c) \quad (4-9)$$

$$s = \frac{1}{1 + \exp(-x)} \quad (4-10)$$

其中更新门用于控制前一层的节点信息被带入到当前层中的程度，更新门的值越大说明前一层的状态信息带入越多，因此得到当前节点的候选集  $\tilde{h}_t$ ，计算如公式4-11所示。其中  $W_h$  为参数矩阵， $\text{concat}$  为拼接函数。重置门控制前一层有多少信息被写入到当前的层节点信息候选集上  $\tilde{h}_t$ ，重置门越小，前一状态的信息被写入的越少，因此可以得到最终的节点向量表示  $h_t$ ，如公式4-12所示。

$$\tilde{h}_t = \tanh(W_h \text{concat}(z_t * h, h')) \quad (4-11)$$

$$h_t = (1 - r_t) * h' + r_t * \tilde{h}_t \quad (4-12)$$

$h_t$  即为每一层 GCN 的输出，经过最后一层 GCN 网络，将会得到一个超节点向量  $e_c$  和文本中的所有单词向量矩阵  $E_w$ ，其中第  $i$  个单词的输出向量为  $e_i$ 。

#### 4.3.4 向量融合及分类

超节点向量  $e_c$  可以视作是方面词的信息向量，一段文本中对于某个方面词的情感倾向应该取决于文本中的某个词或者多个词，而方面词本身大多数仅仅是一个名词，而没有情感色彩。因此需要通过方面词的信息从上下文中找出能代表这个方面词情感的词汇。故而本节依然采用一个多头注意力机制进行查找。通过方面词向量关注对这个词具有感情描述的其他词汇。因此通过注意力机制可以最终得到表示整个文本情感色彩的向量  $e_a$ ，计算过程如公式4-13，4-14，4-15所示。其中  $W'_q$ 、 $W'_k$ 、 $W'_v$  均为用以线性变换的参数矩阵。

$$a_i = \frac{(W'_q e_c)^T (W'_k e_i)}{\sqrt{n}} \quad (4-13)$$

$$\alpha_i = \frac{a_i}{\sum_j \exp(a_j)} \quad (4-14)$$

$$e_a = \sum_j \tanh(W'_v v_j) * \alpha_j \quad (4-15)$$

最终将超节点向量  $e_c$  和向量  $e_a$  进行拼接输入到线性变化层以及一个 softmax 函数得到最终输出向量，其中每一维的数值代表预测归属于某一类别标签的概率，本章算法中选择预测概率最高的标签作为预测标签，以实现方面级情感分类任务。计算过程如公式4-16,4-17所示。其中  $W_o$  为输出层的权重矩阵， $b_o$  为偏置。

$$e_o = \text{concat}(e_c, e_a) \quad (4-16)$$

$$O = \text{softmax}(W_o e_o + b_o) \quad (4-17)$$

该模型利用反向传播（BP）算法进行参数更新，同时使用了 Dropout 防止模型过拟合。模型迭代 N 次，直至收敛，最终模型即可在测试集上验证分类效果，实现方面级情感分析任务。

### 4.4 实验设置

#### 4.4.1 数据集描述及数据处理

本章使用方面级情感分析任务中常用的数据集，包括 Twitter 数据集，其由 Dong 等人构建而来<sup>[58]</sup>，以及另外三种数据集，LAP 14，Rest 14，Rest 15。LAP 14

和 Rest 14 来自于 SemEval 2014 task 4<sup>[59]</sup>, Rest 15 来自于 SemEval 2015 task 12<sup>[60]</sup>, 这四种数据集均为英文数据集。本章分别在这四种数据集上进行验证模型及与其他模型进行对比。

**Twitter** 数据集来自于 Twitter 上的一些关于名人、产品和公司等评论。总共有 6940 个文本, 其中训练集包含 6248 段文本以及 692 个测试集。该数据集共有三种类别, 分别是正向情感, 负面情感以及无情感倾向。以文本 “i love my kindle, i really do.” 为例, 在这个数据集中, 对应的方面词为 “kindle”, 对应的标签为 “1”, 即正面情感。该数据集即需要根据给出的方面词, 判断这个方面词在这段文本中所包含的情感色彩。

**LAP 14** 数据集主要是关于电脑方面的一些评价。总共有 2966 个文本, 其中测试集 638 个, 2328 个训练集。与 twitter 数据集一致, 依然是正向、负面以及无情感三种类别。以句子 “it is the perfect size and speed for me” 为例, 其中 “perfect” 为方面词, 其对应的标签为 “1”, 即正面情感, 可以从单词 “perfect” 得出这个结论。

**Rest 14 和 Rest 15** 两种数据集来自于不同的年份的关于餐厅的评论。Rest 14 包含 4728 个样本, 其中共计 3608 个训练集以及 1120 个测试集。Rest 15 包含 1746 个样本, 其中包括 1204 个训练集以及 542 个测试集, 两者均与上类似为 3 类标签。数据集中的样本如句子 “i recommend this place to everyone” 为例, 这个句子中给定的方面词为 “place”, 从整个句子可以分析出, 对于这个方面词给予的是正面评价, 这从给定的标签为 “1” 得到验证。

数据集中详细统计如表4-1所示。

表 4-1 数据集数据统计

数据集	划分	正向	负向	无倾向
Twitter	训练集	1561	1560	3127
	测试集	173	173	346
LAP14	训练集	994	870	464
	测试集	341	128	169
Rest 14	训练集	2164	807	637
	测试集	728	196	196
Rest 15	训练集	912	256	36
	测试集	326	34	182

本章使用的文本预处理方式与第三章中采用用的方式一致。如果使用 Glove 作为单词初始化向量时, 会对数据集中的所有的单词进行一个唯一编号, 同时将文本按照 “空格” 分词后, 按照单词索引找出对应的单词向量。文本就由一组单



词向量组成。同时超节点的向量采用零向量进行初始化。如果采用 BERT 的预训练模型，则输入到 GCN 中的单词向量为 BERT 模型最后一层的输出，并且超节点向量依然采用零向量进行初始化。

#### 4.4.2 对比方法介绍

本章提出的方法是针对于方面级情感分析任务。因此对比的方法均是近些年常用于比较的模型，且同时比较了采用例如 word2vec 或 glove 作为词向量初始化的模型以及采用基于 BERT 预训练模型的方法。主要比较模型如下：

**SVM:** Kiritchenko 等人<sup>[61]</sup>提出的一种基于支持向量机的方面级情感分析算法。

**LSTM:** Tang 等人<sup>[29]</sup>提出的一种基于 LSTM 模型的算法，该算法使用了 LSTM 模型的最后一层的隐藏状态向量作为分类向量实现情感极性判断。

**MemNet:** Tang 等人<sup>[62]</sup>提出采用一个深层注意力机制捕捉方面词与文本单词之间的关系。相比于基于特征工程的 SVM 和基于序列单元的 LSTM，它们提出的模型在推断一个方面词的情感极性时，更能明确地抓住每个重要的上下文单词。

**AOA:** Huang 等人提出了一个 AOA (Attention-over-Attention) 模型，该模型采用 Bi-LSTM 模型以及注意力机制进行捕捉到方面目标词与文本内容之间的关系信息，从而推断那些词对于方面词情感分析有帮助。

**IAN:** Ma 等人<sup>[63]</sup>提出的基于注意力机制的方法将方面词以及文本上下文内容共同建模，将两者信息交互起来学习，实现多层次语义分析。

**Tnet-LF:** Li 等人<sup>[54]</sup>提出了一个上下文持久化持变换 (Context-Preserving Transformation, CPT) 的概念，保留和加强部分上下文信息。每个 CPT 层包含一个 Bi-LSTM 模型，该模型用以处理方面级的目标词，获取目标词的向量表示。然后将这个向量表示与输入的单词向量进行拼接输入到一个全连接层，最终生成一个新的向量表示，该向量体现了每个单词与目标词之间的关系信息。随后再对 CPT 输出的这组向量表示采用 CNN 模型卷积处理，捕捉关键信息，生成表示文本的向量。

**ASGCN-DT:** Zhang 等人<sup>[35]</sup>提出采用解析树的方式构建文本图，以利用句法信息和单词依存关系，并使用图卷积神经网络 (GCN) 用以学习方面目标单词与文本内容单词之间的关系。

**TG-BERT:** Gao 等人<sup>[64]</sup>提出的一种基于 BERT 的模型。该模型将 BERT 模型中输出的方面词向量采用最大池化的方式挑选最重要的特征生成一个向量，然后结合 BERT 模型中的 cls 向量输入到一个全连接层实现分类任务。

**DGEDT(BiGCN):** Tang 等人<sup>[36]</sup>提出的一种基于双向 GCN 的模型。该模型采用语法解析树的方式构建图，解析树生成的单词之间联系有着前后关系，因此考虑到这种关系，采用了一种双向 GCN 提取信息。通过 GCN 学习单词向量表示以及方面词向量表示，再结合一个注意力机制提出关键信息，实现情感分类任务。

**DGEDT-BERT:** 相比于 DGEDT(BiGCN) 模型，该模型结合了一个 transformer 结构，即一方面采用 transformer 结构学习单词向量表示，另一方面再采用一个双向 GCN 模型学习单词向量表示，接着采用他们提出的一个 BiAffine 模块，将两种方式学到的单词向量融合起来，得到更加具有丰富表示的单词向量。同时，该模型还结合了 BERT 预训练模型，将 BERT 模型的单词输出作为 transformer 结构和 GCN 结构的输入，进一步提升模型分类性能。

**GAGCN 及 GAGCN-BERT:** GAGCN 即为本章提出的算法模型，GAGCN-BERT 代表使用了 BERT 模型的单词输出作为 GAGCN 模型中的单词输入，其他结构不变。

各类模型详细统计如表4-2所示。

表 4-2 算法模型统计

模型	使用 LSTM	使用 GCN	使用注意力机制	使用 BERT
SVM	×	×	×	×
LSTM	✓	×	×	×
MemNet	×	×	✓	×
AOA	✓	×	✓	×
IAN	✓	×	✓	×
Tnet-LF	✓	×	✓	×
ASGCN-DT	✓	✓	✓	×
TG-BERT	×	×	×	✓
DGEDT(BiGCN)	✓	✓	✓	×
DGEDT-BERT	×	✓	✓	✓
GAGCN	×	✓	✓	×
GAGCN-BERT	×	✓	✓	✓

#### 4.4.3 模型参数设置及评价指标

对于本章提出的算法 GAGCN 未使用 BERT 模型输出的词向量，因此采用了 300 维的 Glove 词向量作为单词的初始化。对于使用了 BERT 模型的 GAGCN-BERT，将 BERT 模型的最后一层词向量作为 GAGCN 词向量的输入。BERT 模型本章与 GAGCN 结合，训练过程中进行微调，BERT 参数的学习率为 0.00002。而 GAGCN 模型的参数学习率为 0.0001，且训练过程中 Dropout 为 0.5。文本建模图

过程中的滑动窗口大小定为 5，滑动窗口中每组单词权重设置为 0.2。GCN 层数采用 2 层。其他模型均使用各自论文中的实验结果。

为了测试模型之间的性能，所有数据集均按照标准的划分方式划分为训练集和测试集，模型在训练集上进行训练，在测试集上进行验证。

为验证模型参数的影响，实验中设置了不同大小的网络神经元个数进行方法的对比实验，分别设置了 256,512,768 个神经元个数。多头注意力机制的头数也会一定程度影响模型性能，因此本章也设置了不同个数的注意力头数进行对比。此外，本章算法中提出使用了一个特别的训练技巧，即数据扩充。因为训练样本有限，数据扩充能一定程度上使模型泛化能力更强，进而提升分类性能。方面词本身并不包含情感色彩，而影响对方面词情感极性判断的决定性因素是文本中的其他词汇。因此方面词所处文本位置决定了这个方面词的情感。基于这种思想，该数据扩充方式的实现为，将一段文本中的方面词替换成另外一个文本中的方面词，保证替换后所处的文本位置不变。为验证这种思想的正确性，实验对比了采用数据扩充以及未使用数据扩充的模型。

对于实验效果的评估，与第三章一致，使用准确率（accuracy）和 macro-F1 分数来验证模型的性能。

## 4.5 实验结果及分析

### 4.5.1 模型分类性能分析

本小结对于未使用 BERT 模型的 GAGCN 采用 Glove 词向量作为单词向量初始化，其他对比方法使用论文中的实验数据。

表 4-3 各模型分类性能比较

Models	TWITTER		LAP14		REST14		REST15	
	ACC	F1-score	ACC	F1-score	ACC	F1-score	ACC	F1-score
SVM	63.4	63.3	70.49	-	80.16	-	-	-
LSTM	69.56	67.7	69.28	63.09	78.13	67.47	77.37	55.17
AOA	72.3	70.2	72.62	67.52	79.97	70.42	78.17	57.02
IAN	72.5	70.81	72.05	67.38	79.26	70.09	78.54	52.65
Tnet-LF	72.98	71.43	74.61	70.14	80.42	71.03	78.47	59.47
ASGCN-DT	72.15	70.4	75.55	71.05	80.77	72.02	79.89	61.89
MemNet	71.48	69.9	70.64	65.17	79.61	69.64	77.31	58.28
DGEDT(BiGCN)	72.8	71	76.2	71.8	81.8	72.5	80.4	62.9
GAGCN	73.22	71.66	76.12	71.46	81.61	73.29	80.63	61.45
TG-BERT	76.7	74.3	78.9	74.4	85.1	78.4	-	-
DGEDT-BERT	<b>77.9</b>	<b>75.4</b>	<b>79.8</b>	75.6	<b>86.3</b>	80	84	71
GAGCN-BERT	76.45	74.89	79.6	<b>75.86</b>	86.25	<b>80.14</b>	<b>85.23</b>	<b>72.25</b>

如表4-3所示，展示了不同模型之间的准确率（ACC）和 F1 分数（F1-score）。此表中 GAGCN 和 GAGCN-BERT 方法隐藏层中采用的神经元数为 768，注意力机制头数为 8。

如表4-3所示，对于采用了 BERT 预训练模型的方法明显在准确率以及 F1 分数上高于其他未使用 BERT 模型的方法。说明 BERT 预训练模型的使用能极大地提升方法的性能。这是由于 BERT 模型采用了大量的数据进行预训练，配合下游任务可以实现更快的收敛速度，从而能够有效地提高模型性能。同时 BERT 模型对于每个单词对应都会生成一个词向量，即使一个文本中同一个单词出现在不同的位置，那么这个单词就会有多个词向量，体现了单词在文本上下文中位置的不同而产生的不同含义，而 Glove 每个单词仅有唯一的一个词向量，忽略了一个单词可能在不同语境下具有不同的含义。例如“apple”一词，可能指一种水果，也可能指的是公司名。含义取决于上下文，而 BERT 模型就考虑了上下文关系。此外，从表中可以看出，对于使用 GCN 模型的方法，如 ASGCN-DT、DGEDT(BiGCN) 和 GAGCN 实验效果均表现不错，这是由于这几种方法中通过构建文本图的过程就建立了一种上下文关系，无论是使用滑动窗口构图，或是依赖解析树构图，均展现了单词之间的上下文关系。再通过 GCN 网络节点之间的信息传递，单词之间的信息进行流动，将这种上下文关系融入至单词词向量中，学得更加丰富的单词向量表示。有利于提升模型性能。

对于未采用 BERT 模型，而使用了 GCN 的模型来看，本章提出的 GAGCN 展现了较为优异的性能。相比于 ASGCN-DT，基本在所有数据集上的准确率和 F1 分数都更为优秀，尤其是在 Twitter 数据集上，准确率提升了 1.07%。但是在 REST15 数据集上，F1 分数相对较低。对比 DGEDT(BiGCN) 模型，GAGCN 互有优势，在 Twitter 和 REST15 数据集的准确率上，GAGCN 表现更好，但是其他数据集略微不足，不过差距都不大。相比于其他模型，这三种使用 GCN 的方法无论是准确率或是 F1 分数，均有明显的优势。而 DGEDT(BiGCN) 和 ASGCN-DT 均使用了 LSTM 模型提取单词的隐藏向量表示，LSTM 是序列模型，在计算中无法实现并行运算，这将影响运算性能，而 GAGCN 未使用 LSTM 架构，故在不影响过多分类性能的情况下展现了更好的计算效率。

对于 TG-BERT、DGEDT-BERT 和 GAGCN-BERT 这三种使用 BERT 预训练模型的方法来说，DGEDT-BERT 和 GAGCN-BERT 分类性能更具优势，基本都高于 TG-BERT，尤其是在 REST14 数据集上，这两个方法的准确率高出 TG-BERT 接近 1.2%。由于 TG-BERT 只是简单地将 BERT 模型输出的方面词向量进行了池化以及与 cls 向量拼接进行分类，一定程度上忽略了方面词与文本中的其他词汇的关系。

而 DGEDT-BERT 和 GAGCN-BERT 不仅通过 GCN 网络学习到了更加丰富的词向量表示,还采用了注意力机制,挖掘对方面词具有分类帮助的词汇。DGEDT-BERT 相比于 GAGCN-BERT 多了一个 transformer 结构,这将明显增加计算资源消耗,当计算资源较为贫乏时, GAGCN 更具优势。此外 DGEDT-BERT 采用语法依赖解析树的方式进行文本构图,构图的效果取决于使用的语法解析方法的好坏,而 GAGCN-BERT 采用的是滑动窗口方式构图。GAGCN 也采用过语法解析树的方式生成图,但实际效果远不如滑动窗口的方式,因此对于这两种构图的方式呈现的效果可能取决于具体的模型架构。

### 4.5.2 GAGCN 中使用的 GCN 与普通 GCN 对比

GAGCN 方法中使用的 GCN 包含了注意力机制以及一个门控机制,为对比这两个机制对模型性能的提升,本节实验与普通的未使用注意力机制和门控机制的 GCN 进行对比。这两个对比方法,均未使用 BERT 预训练模型,仅在 GCN 模型上有差异,即是否使用了注意力机制和门控机制,算法的其他部分一致——即采用了相同的文本处理方法、构图方式以及最终的向量融合方式和分类方法。

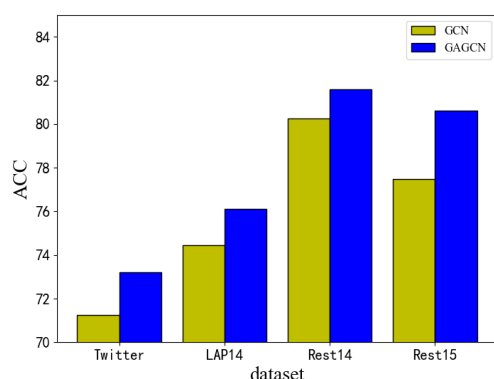


图 4-4 分类准确率 (ACC)




图 4-5 分类 F1 分数 (F1-score)

如图4-4所示,展示了 GAGCN 与普通 GCN 方法的准确率。从图可以看出,在所有的数据集的结果中, GAGCN 都明显高于普通的 GCN,尤其是在 Rest15 数据集上高出了 3.14 个百分点。说明 GAGCN 的注意力机制能够辅助模型找到对当前节点贡献度较高的邻居节点,并更多的获取来自这个邻居节点的信息,同时门控机制控制了当前层与上一层节点信息的选取,自适应选择机制可以帮助模型选择每一层网络中重要的节点信息。F1 分数的结果如图4-5,与准确率的结果一致, GAGCN 显著高于普通的 GCN,且在 Rest15 数据集上高出了 7.87%。因此这两个图结果都能证明 GAGCN 注意力机制和门控机制的有效性。在图节点信息的传播

过程中，通过注意力机制挖掘邻居节点之间的关联程度，辅助节点获取到更关键的信息，有助于提升模型性能。

#### 4.5.3 数据增扩效果验证

本节对 GAGCN-BERT 中提出的数据增扩方法进行了验证。两种形式的参数设置一致，仅有的差异即是在训练过程中是否使用了数据增扩。数据增扩的实现以 LAP 数据集中的句子 “it’s color is even cool” 为例，这里的方面词为 “color”，在训练的过程中，这句话的方面词有 50% 的几率被替换成另一个句子中的方面词，比如 “service”，但标签依然维持不变。训练集中的所有句子均有 50% 被替换成另一个方面词，而测试集不做替换。如图4-6所示，展示了两种训练方式的分类准

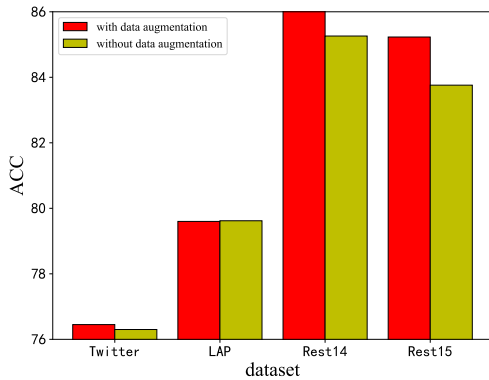


图 4-6 分类准确率 (ACC)




图 4-7 分类 F1 分数 (F1-score)

确率，从图中可以看出，使用了数据增扩的模型在这四种数据集上基本都高于未使用数据增扩的方法，尤其是在 Rest15 数据集上，提升了 1.47%。这可能是由于 Rest15 数据集相比于其他数据集训练样本更少，模型训练样本不足，容易产生过拟合，故采用数据增扩的方式补充一定量的训练样本，有利于提升模型的泛化能力，提升分类性能。如图4-7所示，展示了 F1-score 的对比差异，与准确率结果类似，使用了数据增扩的方法分类性能优于未使用数据增扩的模型，并且在 Rest15 数据集上提升了 10.1 个百分点。差距十分明显。从准确率和 F1 分数的结果来看，本章提出的数据增扩方式对模型性能有一定提升，尤其是在仅有少量训练样本的数据集下表现突出。因为这种数据增扩的方式通过替换方面词，让模型学习过程中不过多依赖方面词本身的含义，而去捕捉语法信息，即方面词所处的上下文位置才是决定情感极性的关键。因此从某种角度上来看这种数据增扩方式一方面增加了训练样本，另一方面引入了人为定义的规则，即让模型不要过多关注于方面词的自身语义，而去关注于单词间的关系以及语法信息。

## 致 谢

在攻读博士学位期间，首先衷心感谢我的导师 XXX 教授

## 附录 A 中心极限定理的证明

### A.1 高斯分布和伯努利实验



## 参考文献

- [1] D. Sculley, G. M. Wachman. Relaxed online svms for spam filtering[C]. Proceedings of the 30th annual international ACM SIGIR conference on Research and development in information retrieval, 2007, 415-422
- [2] H. Saif, Y. He, M. Fernandez, et al. Contextual semantics for sentiment analysis of twitter[J]. Information Processing & Management, 2016, 52(1): 5-19
- [3] K. Xu, W. Hu, J. Leskovec, et al. How powerful are graph neural networks?[J]. arXiv preprint arXiv:1810.00826, 2018
- [4] H. Cai, V. W. Zheng, K. C.-C. Chang. A comprehensive survey of graph embedding: Problems, techniques, and applications[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(9): 1616-1637
- [5] Z. Wu, S. Pan, F. Chen, et al. A comprehensive survey on graph neural networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020
- [6] J. Zhou, G. Cui, Z. Zhang, et al. Graph neural networks: A review of methods and applications[J]. arXiv preprint arXiv:1812.08434, 2018
- [7] Y. Li, D. Tarlow, M. Brockschmidt, et al. Gated graph sequence neural networks[J]. arXiv preprint arXiv:1511.05493, 2015
- [8] P. Veličković, G. Cucurull, A. Casanova, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017
- [9] T. N. Kipf, M. Welling. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016
- [10] K. S. Jones. A statistical interpretation of term specificity and its application in retrieval[J]. Journal of documentation, 1972
- [11] T. Mikolov, K. Chen, G. Corrado, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013
- [12] T. Mikolov, I. Sutskever, K. Chen, et al. Distributed representations of words and phrases and their compositionality[J]. Advances in neural information processing systems, 2013, 26: 3111-3119
- [13] J. Pennington, R. Socher, C. D. Manning. Glove: Global vectors for word representation[C]. Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP), 2014, 1532-1543

- [14] A. Joulin, E. Grave, P. Bojanowski, et al. Bag of tricks for efficient text classification[J]. arXiv preprint arXiv:1607.01759, 2016
- [15] H. Salehinejad, S. Sankar, J. Barfett, et al. Recent advances in recurrent neural networks[J]. arXiv preprint arXiv:1801.01078, 2017
- [16] S. Hochreiter, J. Schmidhuber. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780
- [17] K. Cho, B. Van Merriënboer, C. Gulcehre, et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014
- [18] M. Schuster, K. K. Paliwal. Bidirectional recurrent neural networks[J]. IEEE transactions on Signal Processing, 1997, 45(11): 2673-2681
- [19] Y. Kim. Convolutional neural networks for sentence classification[J]. arXiv preprint arXiv:1408.5882, 2014
- [20] S. Lai, L. Xu, K. Liu, et al. Recurrent convolutional neural networks for text classification[C]. Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence, 2015, 2267-2273
- [21] B. Wang. Disconnected recurrent neural networks for text categorization[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2018, 2311-2320
- [22] L. Mou, G. Li, Z. Jin, et al. Tbcnn: A tree-based convolutional neural network for programming language processing[J]. arXiv preprint arXiv:1409.5718, 2014
- [23] L. Yao, C. Mao, Y. Luo. Graph convolutional networks for text classification[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 7370-7377
- [24] A. Vaswani, N. Shazeer, N. Parmar, et al. Attention is all you need[C]. Advances in neural information processing systems, 2017, 5998-6008
- [25] J. Devlin, M.-W. Chang, K. Lee, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018
- [26] L. Jiang, M. Yu, M. Zhou, et al. Target-dependent twitter sentiment classification[C]. Proceedings of the 49th annual meeting of the association for computational linguistics: human language technologies, 2011, 151-160
- [27] J. Wagner, P. Arora, S. Cortes, et al. Dcu: Aspect-based polarity classification for semeval task 4[J]. SemEval 2014, 2014, 223

- 
- [28] T. Brychcín, M. Konkol, J. Steinberger. Uwb: Machine learning approach to aspect-based sentiment analysis[C]. Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014), 2014, 817-822
- [29] D. Tang, B. Qin, X. Feng, et al. Effective lstms for target-dependent sentiment classification[J]. arXiv preprint arXiv:1512.01100, 2015
- [30] W. Xue, T. Li. Aspect based sentiment analysis with gated convolutional networks[J]. arXiv preprint arXiv:1805.07043, 2018
- [31] B. Huang, K. M. Carley. Parameterized convolutional neural networks for aspect level sentiment classification[J]. arXiv preprint arXiv:1909.06276, 2019
- [32] H. Han, X. Li, S. Zhi, et al. Multi-attention network for aspect sentiment analysis[C]. Proceedings of the 2019 8th International Conference on Software and Computer Applications, 2019, 22-26
- [33] H. Li, Y. Xue, H. Zhao, et al. Co-attention networks for aspect-level sentiment analysis[C]. CCF International Conference on Natural Language Processing and Chinese Computing, 2019, 200-209
- [34] B. Huang, Y. Ou, K. M. Carley. Aspect level sentiment classification with attention-over-attention neural networks[C]. International Conference on Social Computing, Behavioral-Cultural Modeling and Prediction and Behavior Representation in Modeling and Simulation, 2018, 197-206
- [35] C. Zhang, Q. Li, D. Song. Aspect-based sentiment classification with aspect-specific graph convolutional networks[J]. arXiv preprint arXiv:1909.03477, 2019
- [36] H. Tang, D. Ji, C. Li, et al. Dependency graph enhanced dual-transformer structure for aspect-based sentiment classification[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020, 6578-6588
- [37] G. E. Hinton, et al. Learning distributed representations of concepts[C]. Proceedings of the eighth annual conference of the cognitive science society, 1986, 12
- [38] W. L. Hamilton, R. Ying, J. Leskovec. Representation learning on graphs: Methods and applications[J]. arXiv preprint arXiv:1709.05584, 2017
- [39] F. Scarselli, M. Gori, A. C. Tsoi, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2008, 20(1): 61-80
- [40] P. W. Battaglia, R. Pascanu, M. Lai, et al. Interaction networks for learning about objects, relations and physics[J]. arXiv preprint arXiv:1612.00222, 2016

- [41] M. Zhang, Z. Cui, M. Neumann, et al. An end-to-end deep learning architecture for graph classification[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2018, 332
- [42] D. Bahdanau, K. Cho, Y. Bengio. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014
- [43] M.-T. Luong, H. Pham, C. D. Manning. Effective approaches to attention-based neural machine translation[J]. arXiv preprint arXiv:1508.04025, 2015
- [44] Z. Lin, M. Feng, C. N. d. Santos, et al. A structured self-attentive sentence embedding[J]. arXiv preprint arXiv:1703.03130, 2017
- [45] K. Fukushima, S. Miyake. Neocognitron: A self-organizing neural network model for a mechanism of visual pattern recognition[M]. Springer, 1982, 267-285
- [46] A. Krizhevsky, I. Sutskever, G. E. Hinton. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90
- [47] Z. Wu, S. Pan, F. Chen, et al. A comprehensive survey on graph neural networks[J]. arXiv preprint arXiv:1901.00596, 2019
- [48] B. Pang, L. Lee. Seeing stars: Exploiting class relationships for sentiment categorization with respect to rating scales[J]. arXiv preprint cs/0506075, 2005
- [49] J. Tang, M. Qu, Q. Mei. Pte: Predictive text embedding through large-scale heterogeneous text networks[C]. Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2015, 1165-1174
- [50] Z. Yang, D. Yang, C. Dyer, et al. Hierarchical attention networks for document classification[C]. Proceedings of the 2016 conference of the North American chapter of the association for computational linguistics: human language technologies, 2016, 1480-1489
- [51] D. Kingma, J. Ba. Adam: A method for stochastic optimization[J]. Computer Science, 2014
- [52] N. Srivastava, G. Hinton, A. Krizhevsky, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958
- [53] J. Zhou, J. X. Huang, Q. Chen, et al. Deep learning for aspect-level sentiment classification: Survey, vision, and challenges[J]. IEEE access, 2019, 7: 78454-78483
- [54] X. Li, L. Bing, W. Lam, et al. Transformation networks for target-oriented sentiment classification[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2018, 946-956

- 
- [55] Y. Wang, M. Huang, X. Zhu, et al. Attention-based lstm for aspect-level sentiment classification[C]. Proceedings of the 2016 conference on empirical methods in natural language processing, 2016, 606-615
- [56] K. Xu, C. Li, Y. Tian, et al. Representation Learning on Graphs with Jumping Knowledge Networks[J]. arXiv e-prints, 2018, arXiv:1806.03536
- [57] G. Li, M. Muller, A. Thabet, et al. Deepgcns: Can gcns go as deep as cnns?[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2019, 9267-9276
- [58] L. Dong, F. Wei, C. Tan, et al. Adaptive recursive neural network for target-dependent Twitter sentiment classification[C]. Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), Baltimore, Maryland, 2014, 49-54
- [59] M. Pontiki, D. Galanis, J. Pavlopoulos, et al. SemEval-2014 task 4: Aspect based sentiment analysis[C]. Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014), Dublin, Ireland, 2014, 27-35
- [60] M. Pontiki, D. Galanis, H. Papageorgiou, et al. SemEval-2015 task 12: Aspect based sentiment analysis[C]. Proceedings of the 9th International Workshop on Semantic Evaluation (SemEval 2015), Denver, Colorado, 2015, 486-495
- [61] S. Kiritchenko, X. Zhu, C. Cherry, et al. Nrc-canada-2014: Detecting aspects and sentiment in customer reviews[C]. Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014), 2014, 437-442
- [62] D. Tang, B. Qin, T. Liu. Aspect level sentiment classification with deep memory network[C]. Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, Austin, Texas, 2016, 214-224
- [63] D. Ma, S. Li, X. Zhang, et al. Interactive attention networks for aspect-level sentiment classification[C]. Twenty-Sixth International Joint Conference on Artificial Intelligence, 2017, 4068-4074
- [64] Z. Gao, A. Feng, X. Song, et al. Target-dependent sentiment classification with bert[J]. IEEE Access, 2019, 7: 154290-154299

## 攻读硕士学位期间取得的成果

## 外文资料原文

### 1 The OFDM Model of Multiple Carrier Waves

## 外文资料译文

### 1 基于多载波索引键控的正交频分多路复用系统模型